

Transformações e Desafios da Docência em Programação no Brasil: O Papel dos Modelos de Linguagem de Grande Escala

ABSTRACT

The use of Large Language Models (LLMs) has significantly impacted programming education, creating both opportunities and challenges for instructors and students. This study investigates programming instructors' perceptions of the use of LLMs in programming courses. A qualitative study was conducted with ten instructors, and the interviews were analyzed using Bardin's Content Analysis. The results indicate that LLMs can support learning, expand students' repertoire, and assist teaching activities when used critically and purposefully. However, participants also reported concerns regarding dependency, reduced cognitive effort, and challenges related to assessment and academic integrity. A key finding is that the perceived impact of LLMs varies according to the students' academic maturity, with benefits more evident among students with stronger conceptual foundations. The findings also reveal that instructors are adapting their assessment practices by emphasizing authorship, reasoning processes, critical thinking, and the ability to evaluate AI-generated content. These results contribute to a better understanding of how programming instructors are responding to the growing presence of generative AI in educational settings.

KEYWORDS

Modelos de Linguagem de Grande Escala, Inteligência Artificial Generativa, Ensino de Programação, Percepção Docente, IA Generativa na Educação

1 INTRODUÇÃO

A popularização da Inteligência Artificial (IA) generativa, impulsionada pelo lançamento público de ferramentas baseadas em Modelos de Linguagem de Grande Escala (LLMs), como ChatGPT e Copilot, tem promovido mudanças significativas em diferentes áreas da sociedade, incluindo a educação [11, 19]. No contexto do ensino de programação, essas tecnologias passaram a oferecer suporte aos estudantes por meio da geração de código, explicações conceituais e auxílio na resolução de problemas, ampliando as possibilidades de aprendizagem e de desenvolvimento de habilidades técnicas.

Ao mesmo tempo, a rápida evolução dessas ferramentas tem provocado transformações nas práticas pedagógicas adotadas por docentes de programação. Estudos recentes apontam benefícios associados ao uso das LLMs, mas também

destacam preocupações relacionadas à aprendizagem, à autoria das atividades, aos processos avaliativos e às questões éticas envolvidas em sua utilização [15, 22]. Nesse cenário, torna-se necessário compreender como os professores percebem e respondem a essas mudanças.

Diante desse contexto, o objetivo deste trabalho é investigar as perspectivas de docentes sobre o impacto do uso de Modelos de Linguagem de Grande Escala (LLMs) em disciplinas de programação. Para isso, foi conduzida uma pesquisa qualitativa baseada em entrevistas semiestruturadas com professores que atuam em diferentes níveis de formação.

A motivação para este estudo decorre da escassez de pesquisas focadas na perspectiva docente, uma vez que grande parte dos trabalhos existentes concentra-se na percepção dos estudantes. Além disso, a rápida evolução das ferramentas de IA generativa torna necessária a atualização constante do conhecimento sobre seus impactos no contexto educacional [19].

Os resultados indicam que os docentes reconhecem benefícios relevantes das LLMs, especialmente no apoio à aprendizagem e à produtividade dos estudantes. Entretanto, também apontam preocupações relacionadas à dependência excessiva das ferramentas, à redução do esforço cognitivo, à integridade acadêmica e à necessidade de adaptação dos métodos de avaliação.

Como contribuição, este trabalho apresenta evidências empíricas sobre como docentes de programação percebem, utilizam e adaptam suas práticas diante da crescente presença da IA generativa. Os resultados podem auxiliar pesquisadores, gestores educacionais e professores na elaboração de estratégias para a integração ética e eficaz dessas tecnologias no ensino de programação. Os materiais utilizados neste estudo, incluindo o conjunto de dados, instrumentos de coleta e demais artefatos necessários para a replicação, estão disponíveis no site do trabalho¹.

Além desta introdução, o artigo está organizado da seguinte forma: a Seção 2 apresenta os trabalhos relacionados e a fundamentação teórica que embasam o presente estudo; a Seção 3 descreve as configurações do estudo; a Seção 4 apresenta e discute os resultados obtidos; a Seção 5 discute as ameaças à validade do estudo e, por fim, a Seção 6 apresenta as conclusões e sugestões para trabalhos futuros.

2 FUNDAMENTAÇÃO TEÓRICA E TRABALHOS RELACIONADOS

Esta seção apresenta a fundamentação teórica e os trabalhos relacionados que embasam o estudo. Inicialmente, são discutidos os impactos da IA generativa no ensino de programação (Seção 2.1). Em seguida, são abordadas as percepções docentes sobre o uso dessas tecnologias (Seção 2.2) e os desafios

In: Proceedings of the Brazilian Symposium on Multimedia and the Web (WebMedia'2026). Lavras/MG, Brazil. Porto Alegre: Brazilian Computer Society, 2026.

© 2026 SBC – Brazilian Computing Society.
ISSN 2966-2753

¹<https://bulmaengenharia.github.io/PesquisasLLM/>

pedagógicos, éticos e avaliativos associados à sua adoção (Seção 2.3). Por fim, é apresentada uma síntese da literatura e a lacuna de pesquisa que motiva este trabalho (Seção 2.4).

2.1 IA Generativa no Ensino de Programação

Os Modelos de Linguagem de Grande Escala (LLMs) representam uma das principais evoluções recentes da Inteligência Artificial aplicada à educação [14]. Ferramentas como ChatGPT e GitHub Copilot são capazes de gerar código, explicar conceitos e auxiliar na resolução de problemas, modificando a forma como estudantes interagem com conteúdos de programação [19]. Além disso, estudos recentes indicam que a qualidade das respostas produzidas pelas LLMs também é influenciada pela complexidade da tarefa e pela especificidade dos *prompts* fornecidos pelos usuários [4].

Estudos empíricos têm investigado os efeitos dessas tecnologias no processo de aprendizagem. Xue et al. [24] observaram que estudantes que utilizaram ChatGPT concluíram atividades em menos tempo, embora sem ganhos significativos de desempenho acadêmico. De forma semelhante, Sampaio et al. [20] identificaram potencial para estimular o raciocínio crítico quando a ferramenta é utilizada de maneira orientada.

Esses resultados sugerem que os impactos das LLMs vão além da simples automação de tarefas, repercutindo nos processos de ensino e aprendizagem. Dessa forma, torna-se relevante compreender como os docentes percebem essas mudanças no contexto de suas disciplinas.

2.2 Percepções Docentes sobre IA Generativa

A percepção dos professores desempenha papel fundamental na adoção de novas tecnologias educacionais, uma vez que influencia decisões relacionadas ao planejamento didático, às estratégias de ensino e aos métodos de avaliação.

Nesse contexto, Lau e Guo [15] investigaram instrutores de programação introdutória e identificaram percepções positivas relacionadas ao apoio à aprendizagem, mas também preocupações com integridade acadêmica e uso inadequado das ferramentas. De forma semelhante, Zastudil et al. [25] observaram que docentes reconhecem oportunidades associadas à IA generativa, mas demonstram incertezas quanto aos seus efeitos de longo prazo sobre a formação dos estudantes.

Embora esses estudos tenham contribuído para a compreensão inicial do fenômeno, muitos foram realizados em disciplinas introdutórias ou analisaram conjuntamente estudantes e docentes. Assim, permanece a necessidade de aprofundar a compreensão da perspectiva dos professores de programação em diferentes contextos educacionais.

2.3 Desafios Pedagógicos, Éticos e Avaliativos

A incorporação de IA generativa no ensino de programação tem provocado discussões sobre autoria, integridade acadêmica e efetividade dos processos avaliativos. A facilidade de obtenção de soluções prontas desafia modelos tradicionais de avaliação centrados exclusivamente na produção de código.

Kirova et al. [13] argumentam que o ensino de Computação deve priorizar competências como pensamento crítico, resolução de problemas e avaliação de soluções produzidas por IA. Outros estudos também apontam preocupações relacionadas à dependência excessiva das ferramentas e à dificuldade de verificar a real aprendizagem dos estudantes [15, 25].

Essas evidências indicam que a adoção das LLMs demanda adaptações pedagógicas e avaliativas. Nesse sentido, compreender como docentes têm respondido a esses desafios constitui um dos principais focos desta pesquisa.

2.4 Síntese e Lacuna de Pesquisa

A literatura demonstra que as LLMs possuem potencial para apoiar o ensino de programação, mas também introduzem desafios relacionados à aprendizagem, avaliação e ética. Apesar do crescimento das pesquisas na área, observa-se que grande parte dos estudos concentra-se na perspectiva discente ou em contextos específicos de utilização das ferramentas.

Diante desse cenário, o presente trabalho busca ampliar o entendimento sobre o tema ao investigar especificamente as percepções de docentes de programação acerca dos benefícios, desafios, adaptações pedagógicas e questões éticas associadas ao uso de IA generativa em suas disciplinas.

3 CONFIGURAÇÃO DO ESTUDO

Esta seção apresenta a configuração do estudo. Inicialmente, é descrito o desenho da pesquisa e as questões de pesquisa que orientaram a investigação (Seção 3.1). Em seguida, são apresentados os participantes e os instrumentos utilizados na coleta de dados (Seção 3.2), bem como os procedimentos adotados para a coleta das entrevistas e dos questionários (Seção 3.3). Por fim, é descrito o processo de análise dos dados, incluindo a aplicação da Análise de Conteúdo de Bardin e as categorias temáticas identificadas (Seção 3.3).

3.1 Desenho da Pesquisa

Este estudo caracteriza-se como uma pesquisa qualitativa, de natureza exploratória e descritiva. A abordagem exploratória foi adotada por investigar um fenômeno recente relacionado ao uso de Modelos de Linguagem de Grande Escala (LLMs) no ensino de programação, enquanto o caráter descritivo permitiu compreender e registrar as percepções e experiências dos docentes participantes sem interferência do pesquisador no contexto investigado [18].

A pesquisa foi conduzida por meio de entrevistas semiestruturadas complementadas por um questionário de caracterização dos participantes. O estudo foi orientado pelas quatro questões de pesquisa, que abordam percepções docentes, benefícios e preocupações associados às LLMs, adaptações avaliativas e desafios éticos relacionados ao seu uso no ensino de programação.

- **RQ1:** Quais são as percepções dos docentes de disciplinas de programação sobre o uso da IA generativa no processo de ensino e aprendizagem?
- **RQ2:** Quais benefícios e preocupações os docentes identificam no uso da IA generativa em suas disciplinas?

Tabela 1: Questões representativas do roteiro de entrevista semiestruturado.

Questão	Tema	Objetivo
Qual é a sua percepção do uso de IA/LLM em atividades propostas pelos alunos de programação na sua disciplina?	Uso de IA na educação	Compreender as percepções docentes sobre o uso de LLMs no ensino de programação.
Na sua percepção, a qualidade da aprendizagem dos alunos com o advento da IA melhorou ou piorou?	Qualidade da aprendizagem	Investigar os impactos percebidos da IA no processo de aprendizagem.
Como você percebe o impacto dos LLMs no desenvolvimento de habilidades de raciocínio lógico e resolução de problemas?	Desenvolvimento cognitivo	Analisar a influência das LLMs no desenvolvimento de competências cognitivas.
Como você está lidando com atividades de programação para evitar respostas diretamente fornecidas por IA?	Estratégias docentes	Identificar adaptações pedagógicas adotadas pelos docentes.
Você planeja mudar o mecanismo de avaliação?	Avaliação da aprendizagem	Investigar mudanças nas estratégias de avaliação após a popularização das LLMs.
Você acredita que o papel do professor de programação está mudando com o avanço dos LLMs? Se sim, como?	Futuro da docência	Compreender as transformações percebidas na atuação docente.

- **RQ3:** Como os docentes de programação têm adaptado suas práticas de avaliação após a popularização da IA generativa?
- **RQ4:** Quais desafios éticos os docentes percebem no uso de IA generativa no ensino de programação?

3.2 Participantes e Instrumentos

A construção dos instrumentos de coleta foi baseada em uma revisão exploratória da literatura realizada nas bases IEEE, ACM e Scopus, complementada pela técnica de *snowballing*. Como referência principal para definição dos temas investigados foram utilizados os estudos de Prather et al. [19], Wang et al. [22] e Lau e Guo [15].

O instrumento principal foi um roteiro de entrevistas, inicialmente composto por 10 questões. Antes da coleta definitiva, foi conduzida uma entrevista piloto com dois docentes de programação para avaliar a clareza, a compreensão e a adequação das perguntas. Com base nos resultados obtidos, o roteiro foi revisado e ampliado, passando a conter 26 questões. Essa reformulação incluiu a inserção de questões complementares destinadas a aprofundar as discussões e favorecer uma conversa mais fluida durante as entrevistas. Os participantes da etapa piloto não integraram a amostra final.

Além das entrevistas, foi aplicado um questionário contendo dez questões destinadas à caracterização dos participantes. Participaram do estudo dez docentes brasileiros da área de Computação com experiência em disciplinas de programação antes e após a popularização das LLMs. Os participantes possuíam entre cinco e mais de dez anos de experiência docente e atuavam em disciplinas como Lógica de Programação, Programação Orientada a Objetos, Estrutura de Dados e Banco de Dados. Os docentes estavam distribuídos entre os estados do Ceará (6), Minas Gerais (2), São Paulo (1) e Piauí (1).

A Figura 1 apresenta o processo de construção dos instrumentos de coleta, enquanto a Tabela 1 apresenta exemplos representativos das questões utilizadas nas entrevistas.

3.3 Coleta de Dados

A coleta de dados ocorreu entre dezembro de 2025 e junho de 2026 e foi realizada em três etapas. Inicialmente, os participantes receberam esclarecimentos sobre os objetivos da pesquisa e manifestaram seu consentimento por meio do Termo de Consentimento Livre e Esclarecido (TCLE). Em seguida, foram conduzidas entrevistas semiestruturadas individuais por meio da plataforma Google Meet. Por fim, os participantes responderam ao questionário de caracterização.

As entrevistas tiveram duração prevista entre 30 e 45 minutos, embora a maioria tenha se aproximado de 50 minutos. Todas as sessões foram gravadas mediante autorização dos participantes e posteriormente transcritas utilizando software de reconhecimento de fala, seguido de revisão manual para correção de eventuais inconsistências.




Figura 1: Estratégia para construção do roteiro de entrevista.

Tabela 2: Etapas da Análise de Conteúdo adotadas na pesquisa.

Etapa	Objetivo	Procedimentos realizados
Pré-análise	Organizar e preparar o corpus da pesquisa.	Transcrição das entrevistas, conferência dos registros e leitura flutuante para organização e familiarização com o corpus.
Exploração do material	Codificar e categorizar os dados.	Segmentação das falas em unidades de registro, codificação e agrupamento em categorias temáticas.
Tratamento dos resultados, inferência e interpretação	Organizar os resultados, realizar inferências e interpretar os dados.	Consolidação das categorias, enumeração das unidades de registro por frequência de ocorrência, discussão dos resultados à luz do referencial teórico e interpretação dos achados.

3.4 Análise dos Dados

Os dados foram analisados por meio da Análise de Conteúdo proposta por Bardin [2], utilizando a modalidade de análise temática. O processo foi conduzido em três etapas: pré-análise, exploração do material e tratamento dos resultados [21].

Na pré-análise, as entrevistas foram transcritas, organizadas e submetidas à leitura flutuante para familiarização com o corpus. Na etapa de exploração do material, as falas foram codificadas e agrupadas em categorias temáticas relacionadas às percepções, desafios e estratégias docentes frente ao uso da IA generativa. Por fim, realizou-se o tratamento dos resultados, incluindo interpretação das categorias identificadas e discussão dos achados à luz da literatura.

A Tabela 2 apresenta uma síntese das etapas da análise, enquanto as Tabelas 3 e 4 apresentam as categorias, subcategorias e exemplos de códigos identificados durante a análise.


As principais categorias identificadas foram: (i) percepção e diagnóstico inicial do uso da IA; (ii) impactos na aprendizagem; (iii) estratégias de adaptação docente; (iv) impacto cognitivo e dependência; e (v) ética, detecção e políticas institucionais. Essas categorias constituem a base da apresentação e discussão dos resultados nas seções subsequentes.

4 RESULTADOS E DISCUSSÃO

Esta seção apresenta os resultados obtidos a partir das entrevistas com os docentes. Os achados são organizados conforme as questões de pesquisa (RQ1 a RQ4) e discutidos à luz da literatura, buscando compreender como a popularização das LLMs tem impactado o ensino de programação.

4.1 Percepções docentes sobre o uso de LLMs no ensino de programação (RQ1)

Os resultados indicam que o uso de ferramentas baseadas em LLMs já faz parte da rotina dos estudantes de programação, sendo reconhecido por todos os docentes participantes. De modo geral, os entrevistados diferenciaram dois padrões de

**Figura 2: Frequência de ativação dos códigos associados à RQ1.**

utilização: um uso orientado à aprendizagem, no qual as ferramentas são empregadas para esclarecer dúvidas e apoiar a resolução de problemas, e um uso baseado na delegação das atividades, sem análise crítica dos resultados produzidos.

Essa percepção converge com estudos anteriores que apontam que os impactos educacionais das LLMs dependem menos da tecnologia em si e mais da forma como ela é utilizada pelos estudantes [19, 25]. Um dos docentes resumiu essa distinção ao afirmar que utilizar uma LLM para apoiar o entendimento é diferente de simplesmente solicitar uma solução e utilizá-la sem interpretação (D1).

Outro aspecto recorrente foi a percepção das LLMs como um potencial “tutor permanente”, disponível para apoiar estudantes fora da sala de aula. Entretanto, os participantes ressaltaram que esse potencial só se concretiza quando existe uso consciente e mediação pedagógica adequada. Essa percepção também é consistente com os resultados de Liu et al. [16], os estudantes e professores perceberam a IA como um “tutor pessoal”, capaz de fornecer suporte aos código, no esclarecimento de dúvidas e na melhoria da qualidade das soluções desenvolvidas.

Diferentemente dos resultados obtidos por Lau e Guo [15], nenhum dos participantes defendeu a proibição dessas ferramentas. Pelo contrário, prevaleceu a percepção de que a integração orientada representa uma estratégia mais efetiva do que tentativas de restrição. Essa perspectiva também é consistente com a proposta de Alzubaidi et al. [1], que defendem a integração das LLMs aos currículos de programação como ferramentas de apoio ao processo de aprendizagem, e não como substitutas do estudante.

A Figura 2 apresenta a frequência de ativação dos códigos associados à RQ1. Observa-se que o código *Consciente* foi mencionado por todos os docentes (100%), indicando consenso quanto à necessidade de um uso crítico e reflexivo das LLMs. Também se destacam os códigos *Aprendizado* (80%) e *Tutor IA* (70%), sugerindo que os docentes reconhecem o potencial dessas ferramentas como apoio ao processo de aprendizagem. Por outro lado, os códigos *Indiscriminado*

Tabela 3: Categorias e subcategorias resultantes da análise temática.

Categoria	Descrição	Subcategorias
CAT. 1	Percepção e diagnóstico inicial do uso	1.1 IA como ferramenta de aprendizagem potencial; 1.2 Uso inadequado e dependência; 1.3 Maturidade acadêmica como variável moderadora.
CAT. 2	Impacto na qualidade da aprendizagem	2.1 Polarização de desempenho; 2.2 Qualidade e autoria das entregas; 2.3 Raciocínio lógico e autonomia intelectual.
CAT. 3	Estratégias de adaptação docente	3.1 Reformulação das avaliações; 3.2 Incentivo ao uso crítico e orientado; 3.3 Papel institucional e perspectiva histórica.
CAT. 4	Impacto cognitivo e dependência	4.1 Dependência cognitiva gerada pelo uso irrestrito; 4.2 Mascaramento das dificuldades iniciais; 4.3 Uso maduro como contraponto positivo.
CAT. 5	Ética, detecção e políticas institucionais	5.1 Estratégias éticas no uso das LLMs; 5.2 Detecção e manejo do uso indevido; 5.3 Políticas institucionais: lacuna percebida.
CAT. 6	Adaptações metodológicas e avaliativas	6.1 Integração intencional das LLMs nas atividades; 6.2 Substituição de formatos avaliativos; 6.3 IA como apoio ao trabalho docente.

Tabela 4: Exemplos de códigos identificados durante a análise temática.

Cat.	Subcategoria	Exemplos de códigos
1.1	IA como ferramenta de aprendizagem potencial	Uso consciente e orientado; IA como tutor permanente; suporte ao aprendizado contínuo.
1.2	Uso inadequado e dependência	Uso indiscriminado sem avaliação crítica; dependência e redução da iniciativa; delegação do raciocínio à IA.
2.1	Polarização de desempenho	Potencialização dos bons alunos; manutenção da proporção entre perfis; piora para alunos passivos.
2.2	Qualidade e autoria das entregas	Entregas corretas sem autoria real; superficialidade do conteúdo produzido; velocidade aumentada e profundidade reduzida.
2.3	Raciocínio lógico e autonomia intelectual	Risco à criatividade; raciocínio lógico como habilidade central; preguiça cognitiva.
3.1	Reformulação das avaliações	Migração para avaliações presenciais; avaliação do processo; impossibilidade de exercícios domiciliares.
3.2	Incentivo ao uso crítico e orientado	Estímulo com responsabilidade pedagógica; validação de fontes; uso moderado como suporte.
5.1	Estratégias éticas no uso das LLMs	Transparência e autoria; propriedade intelectual; referências bibliográficas inexistentes.
5.2	Detecção e manejo do uso indevido	Indícios de geração por IA; uso de estruturas não ensinadas; conversa individual com o estudante.
4.1	Dependência cognitiva gerada pelo uso irrestrito	Substituição do esforço pelo resultado imediato; perda da capacidade de resolver sem a ferramenta; dependência comparada a outras tecnologias.
4.2	Mascaramento das dificuldades iniciais	IA ocultando lacunas de raciocínio nos iniciantes; ansiedade e imediatismo como agravantes; lógica e estrutura de dados como disciplinas sensíveis.
4.3	Uso maduro como contraponto positivo	Ampliação de repertório em alunos avançados; IA como parceiro em contextos aplicados; nicho técnico como limitador natural da dependência.
6.1	Integração intencional das LLMs nas atividades	IA como objeto de análise crítica pelo aluno; avaliação do prompt como evidência de raciocínio; IA com respostas erradas como recurso pedagógico.
6.2	Substituição de formatos avaliativos	Substituição de trabalhos escritos por apresentações; uso de vídeo e áudio como alternativa; avaliação em papel como blindagem à IA.
6.3	IA como apoio ao trabalho docente	Uso pelo professor na preparação de aulas; ganho de tempo para aprofundamento pedagógico; geração de dinâmicas e conteúdos novos.

(90%), *Delegação* (90%) e *Dependência* (80%) evidenciam preocupações recorrentes relacionadas ao uso excessivo ou pouco reflexivo das ferramentas pelos estudantes. Além disso, os códigos associados à maturidade acadêmica indicam que os docentes percebem diferenças importantes na forma como as LLMs são utilizadas, destacando que estudantes mais experientes tendem a obter melhores resultados com essas tecnologias (*Qualificado*, 70%), enquanto seu uso pode ser mais prejudicial em contextos introdutórios (*Prejudicial*, 80%).

4.2 Benefícios e preocupações associados ao uso de LLMs (RQ2)

Os docentes identificaram benefícios e preocupações relacionados ao uso das LLMs, indicando que seus impactos variam de acordo com o perfil dos estudantes e o contexto de utilização.

Entre as principais preocupações, destacou-se a dependência excessiva da ferramenta. Os participantes relataram que estudantes menos engajados tendem a utilizar as LLMs como substitutas do processo de resolução de problemas, enquanto estudantes mais comprometidos as utilizam para ampliar conhecimentos e explorar novas abordagens. Os resultados também convergem com Zönnchen et al. [26], que identificaram que os benefícios das LLMs são mais evidentes entre estudantes com maior domínio dos conteúdos. Esse resultado sugere que as LLMs podem amplificar características acadêmicas já existentes, potencializando tanto comportamentos positivos quanto negativos.

Essa percepção é consistente com estudos que apontam riscos relacionados à redução do esforço cognitivo e à dependência tecnológica [12]. Os docentes demonstraram preocupação especialmente com o desenvolvimento do raciocínio lógico, da autonomia intelectual e da capacidade de resolver problemas de forma independente, competências tradicionalmente consideradas centrais na formação em Computação. Por outro lado, Philbin [17] argumenta que, quando utilizadas de forma orientada, ferramentas baseadas em IA podem reduzir a carga cognitiva dos estudantes, especialmente dos iniciantes, ao apoiar a compreensão de código e a resolução de problemas.

Outro resultado relevante refere-se à influência da maturidade acadêmica. Os participantes observaram que os riscos associados às LLMs tendem a ser mais evidentes em disciplinas introdutórias, nas quais os estudantes ainda estão desenvolvendo conceitos fundamentais de lógica e programação. Becker et al. [3] também destaca desafios imediatos para o ensino introdutório de programação. Em contrapartida, em disciplinas avançadas, as ferramentas foram percebidas como recursos capazes de ampliar repertório, acelerar tarefas operacionais e apoiar projetos mais complexos. Esse achado sugere que a maturidade acadêmica atua como uma variável moderadora importante na relação entre estudantes e IA generativa.

Os docentes também destacaram que os benefícios das LLMs tendem a ser mais evidentes em estudantes com maior maturidade acadêmica. Nesses casos, as ferramentas são utilizadas para ampliar repertório, apoiar o desenvolvimento

de software, revisar código e explorar soluções mais sofisticadas. Essa percepção também é consistente com Haindl e Weinberger [8], que observaram que o uso do ChatGPT pode contribuir para a produção de códigos mais limpos, menos complexos e mais aderentes às boas práticas de programação. Alguns participantes relataram que estudantes envolvidos em projetos avançados, pesquisa ou competições de programação utilizam as LLMs como apoio para aprofundar conhecimentos e acelerar tarefas operacionais sem substituir o raciocínio necessário para resolução dos problemas. Essa percepção converge com Philbin [17] e Hernandez et al. [9], que argumenta que essas ferramentas podem favorecer o engajamento e a criatividade dos estudantes em atividades baseadas em projetos, atuando como colaboradoras durante o processo de desenvolvimento. Além disso, em conteúdos mais especializados, as limitações das próprias ferramentas foram percebidas como um estímulo à autonomia intelectual, uma vez que os estudantes precisam validar, complementar e adaptar as respostas geradas pela IA. Esses resultados sugerem que os benefícios das LLMs estão fortemente associados à capacidade dos estudantes de utilizar criticamente as informações produzidas pelos modelos.

Além dos impactos sobre os estudantes, todos os docentes relataram utilizar LLMs em suas próprias atividades profissionais. Os principais benefícios mencionados envolveram a preparação de aulas, elaboração de exercícios, produção de materiais didáticos e apoio ao planejamento pedagógico. Os resultados indicam que as ferramentas permitem reduzir o tempo dedicado a tarefas operacionais, possibilitando maior foco em atividades de natureza pedagógica e estratégica.

Em síntese, os resultados mostram que as LLMs apresentam potencial para apoiar tanto estudantes quanto docentes. Porém o resultado difere do observado por Prather et al. [19], no qual a maioria dos instrutores declarou ainda não utilizar ferramentas de IA generativa ou apenas manifestou a intenção de adotá-las futuramente. Entretanto, os benefícios percebidos dependem fortemente do nível de maturidade acadêmica, da capacidade de avaliação crítica e da mediação pedagógica exercida pelo professor.

4.3 Adaptações das práticas avaliativas (RQ3)

Os resultados indicam que a popularização das LLMs tem provocado mudanças significativas nas estratégias de avaliação adotadas pelos docentes. A principal transformação observada foi a redução da confiança em atividades realizadas fora de ambientes supervisionados, acompanhada pela valorização de mecanismos capazes de evidenciar o processo de construção do conhecimento.

Entre as adaptações relatadas destacam-se a ampliação do peso de avaliações presenciais, a realização de arguições orais e a adoção de atividades que exigem justificativa e explicação das soluções produzidas. Essas estratégias buscam reduzir a ênfase no produto final e aumentar a importância do raciocínio empregado pelos estudantes, resultado alinhado às discussões apresentadas por Lau e Guo [15].

Além das medidas voltadas ao controle e verificação da aprendizagem, alguns docentes relataram iniciativas de integração das LLMs ao processo avaliativo. Nesses casos, a avaliação deixa de focar somente na resposta produzida e passa a considerar aspectos como a formulação de *prompts*, a análise crítica dos resultados gerados e a capacidade de identificar limitações ou erros apresentados pela ferramenta. Essa abordagem aproxima-se das recomendações de White et al. [23], que destacam a formulação de instruções eficazes como uma competência relevante em contextos mediados por IA. Essa perspectiva também é consistente com os achados de França et al. [7], que evidenciam a importância da elaboração de *prompts* para a obtenção de respostas mais adequadas em tarefas apoiadas por LLMs. Além disso, Jonsson e Tholander [10] evidenciam a interação com modelos generativos como um processo colaborativo, no qual a elaboração de *prompts* e a reflexão sobre as respostas produzidas constituem parte do próprio processo de aprendizagem.

De modo geral, os resultados sugerem que as adaptações avaliativas têm ocorrido em duas frentes: o fortalecimento de mecanismos voltados à demonstração da aprendizagem e a incorporação gradual das LLMs como recurso pedagógico. A Figura 3 sintetiza o modelo conceitual emergente das entrevistas, evidenciando que as adaptações docentes ocorrem em duas abordagens complementares. A primeira está relacionada à verificação da autoria e da compreensão dos estudantes através de estratégias como provas presenciais, arguições e explicação das soluções. A segunda envolve a integração pedagógica das LLMs, incluindo atividades com elaboração de *prompts* e análise crítica de respostas geradas por IA. Ambas as abordagens sugerem que a principal transformação observada não está na substituição das avaliações tradicionais, mas na valorização de competências cognitivas e metacognitivas que permanecem relevantes mesmo em contextos amplamente mediados por IA generativa.

4.4 Desafios éticos associados ao uso de IA generativa (RQ4)

Os desafios éticos identificados pelos docentes concentram-se em três dimensões principais: integridade acadêmica, responsabilidade docente e ausência de diretrizes institucionais.

Na dimensão da integridade acadêmica, os participantes relataram situações em que conteúdos produzidos por IA foram apresentados como trabalhos autorais dos estudantes, sem transparência sobre o uso da ferramenta. Em resposta, os docentes passaram a valorizar não apenas o produto final, mas também a capacidade dos estudantes de explicar, justificar e defender as soluções apresentadas. Essa mudança sugere uma redefinição do conceito de autoria em contextos mediados por IA, perspectiva discutida em estudos recentes sobre integridade acadêmica e IA generativa [6, 19].

Outro aspecto recorrente foi a percepção de que os próprios docentes possuem responsabilidade ética na orientação do uso dessas tecnologias. Os participantes argumentaram que simplesmente disponibilizar as ferramentas aos estudantes sem



Figura 3: Modelo conceitual das adaptações das práticas avaliativas docentes identificadas na RQ3.

orientação adequada pode comprometer o processo formativo e favorecer práticas inadequadas de utilização, conforme discutido por Estaphan et al. [5].

Por fim, praticamente todos os entrevistados relataram ausência ou insuficiência de políticas institucionais relacionadas ao uso de IA generativa. Os docentes demonstraram incertezas sobre critérios de utilização aceitável, formas de avaliação e estratégias institucionais para integração dessas tecnologias ao ensino. Esse resultado sugere que os desafios éticos associados às LLMs extrapolam o comportamento individual dos estudantes, envolvendo também questões institucionais e pedagógicas.

4.5 Síntese dos Achados

Os resultados indicam que os docentes reconhecem o potencial das LLMs para apoiar a aprendizagem e ampliar a produtividade tanto de estudantes quanto de professores. Entretanto, também identificam riscos relacionados à dependência excessiva, à redução da autonomia intelectual e aos desafios de avaliação e integridade acadêmica.

Os achados sugerem que a maturidade acadêmica desempenha papel central na forma como os estudantes utilizam essas tecnologias. Enquanto alunos mais experientes tendem

a utilizá-las de maneira estratégica e reflexiva, estudantes iniciantes apresentam maior vulnerabilidade ao uso passivo e à delegação do raciocínio.

Diante desse cenário, os docentes têm adaptado suas práticas pedagógicas e avaliativas, deslocando o foco da simples produção de respostas para a demonstração do processo de aprendizagem, do pensamento crítico e da capacidade de utilizar a IA de forma consciente. Esses resultados reforçam a necessidade de integrar as LLMs ao ensino de programação de maneira planejada, crítica e pedagogicamente orientada.

5 AMEAÇAS À VALIDADE

Esta seção discute as principais ameaças à validade do estudo e as estratégias adotadas para reduzir seus possíveis impactos, considerando as categorias de validade de construção, interna, externa e de conclusão.

5.1 Validade de Construção

A validade de construção refere-se à adequação dos instrumentos utilizados para investigar os fenômenos de interesse. Neste estudo, existe o risco de que as questões da entrevista não capturassem integralmente as percepções dos docentes sobre o uso de LLMs no ensino de programação. Para mitigar essa ameaça, o roteiro foi elaborado com base em estudos da literatura relacionados à adoção de IA generativa na educação e passou por uma etapa de validação por meio de entrevistas piloto com docentes da área. Além disso, os participantes da fase piloto foram excluídos da amostra final, evitando possíveis vieses decorrentes do contato prévio com versões preliminares do instrumento.

Outra ameaça refere-se à interpretação das respostas pelos pesquisadores durante a codificação e categorização dos dados. Para reduzir esse risco, foi adotada a Análise de Conteúdo de Bardin, utilizando categorias temáticas definidas de forma sistemática a partir das evidências presentes nas entrevistas.

5.2 Validade Interna

A validade interna está relacionada à interpretação dos resultados e às relações estabelecidas entre os achados observados. Como o estudo baseia-se em percepções e experiências relatadas pelos participantes, existe a possibilidade de vieses individuais influenciarem as respostas, incluindo experiências específicas com determinadas ferramentas ou contextos institucionais particulares.

Além disso, o tema investiga tecnologias em rápida evolução, o que influencia a forma como os docentes percebem os impactos das LLMs. Para amenizar essa influência, foram entrevistados docentes com diferentes perfis, experiências profissionais e áreas de atuação dentro da Computação, permitindo a identificação de padrões recorrentes entre os relatos.

5.3 Validade Externa

A validade externa refere-se à possibilidade de generalização dos resultados. Este estudo foi conduzido com dez docentes brasileiros da área de Computação que atuam em disciplinas

de programação. Embora a amostra tenha contemplado participantes de diferentes instituições e estados, os resultados refletem percepções de um grupo específico de docentes e não devem ser generalizados para todos os contextos educacionais.

Entretanto, o objetivo da pesquisa qualitativa não é produzir generalizações estatísticas, mas compreender em profundidade um fenômeno contemporâneo. Dessa forma, os resultados fornecem evidências que podem auxiliar pesquisadores e educadores na compreensão de contextos semelhantes.

5.4 Validade de Conclusão

A validade de conclusão está relacionada à consistência das inferências realizadas a partir dos dados coletados. Como toda análise qualitativa envolve interpretação dos pesquisadores, existe o risco de que determinadas categorias ou relações identificadas reflitam parcialmente a visão dos autores.

Para minimizar tal risco, as conclusões foram fundamentadas em evidências provenientes das entrevistas, apoiadas por exemplos representativos das falas dos participantes e discutidas à luz da literatura existente. Adicionalmente, o uso de frequências de ocorrência dos códigos teve caráter complementar, sendo empregada apenas para apoiar a interpretação qualitativa dos resultados, e não como evidência estatística.

6 CONCLUSÃO

Este trabalho investigou as percepções de docentes de programação sobre os impactos dos Modelos de Linguagem de Grande Escala (LLMs) no ensino e na aprendizagem. Os resultados indicam que essas tecnologias já estão amplamente presentes no contexto educacional, sendo percebidas simultaneamente como oportunidade e desafio.

Os docentes destacaram benefícios relacionados ao apoio à aprendizagem, à ampliação do repertório dos estudantes e ao suporte às atividades pedagógicas. Em contrapartida, foram identificadas preocupações associadas à dependência excessiva da ferramenta, à redução da autonomia intelectual, aos desafios de avaliação e às questões de integridade acadêmica. Os resultados também sugerem que a maturidade acadêmica influencia o uso das LLMs pelos estudantes, com benefícios mais evidentes em alunos com maior domínio conceitual.

Além disso, observou-se que os docentes têm adaptado suas práticas pedagógicas e avaliativas, valorizando cada vez mais a demonstração do raciocínio, do pensamento crítico e da autoria. De modo geral, os achados reforçam a importância de integrar as LLMs ao ensino de programação de forma crítica, ética e pedagogicamente orientada.

Como trabalhos futuros, sugere-se ampliar o número de participantes e investigar a percepção de estudantes, bem como avaliar empiricamente diferentes estratégias de integração das LLMs ao ensino de programação.

7 AGRADECIMENTOS

O ChatGPT foi usado para correção textual e melhoramento das figuras. Vale ressaltar que o ChatGPT não foi utilizado para a análise das entrevistas.

REFERÊNCIAS

- [1] Rania Alzubaidi, Iyas Qaddara, and Insaf Kraidia. 2026. AI-Augmented Co-Learning: A Conceptual Framework for Integrating Large Language Models into Programming Curricula. In *2026 1st International Conference on Emerging Technologies and Engineering Systems (ICETES)*. Amman, Jordan. doi:10.1109/ICETES68504.2026.11518751
- [2] Laurence Bardin. 2016. *Análise de Conteúdo* (1 ed.). Edições 70, São Paulo.
- [3] Brett A. Becker, Paul Denny, James Finnie-Ansley, Andrew Luxton-Reilly, James Prather, and Eddie Antonio Santos. 2023. Programming Is Hard – Or at Least It Used to Be: Educational Opportunities and Challenges of AI Code Generation. In *Proceedings of the 54th ACM Technical Symposium on Computer Science Education (SIGCSE 2023)*. Toronto, ON, Canada.
- [4] Antonio Cruz, Paulo H. L. Rettore, and Bruno P. Santos. 2025. Análise do Uso de Modelos de Linguagem de Grande Escala na Geração de Códigos para Automação Residencial. In *Proceedings of the Brazilian Symposium on Multimedia and the Web (WebMedia 2025)*. doi:10.5753/webmedia.2025.38762
- [5] Suzanne Estaphan, David Kramer, and Harry J. Witchel. 2025. Navigating the Frontier of AI-Assisted Student Assignments: Challenges, Skills, and Solutions. *Advances in Physiology Education* 49, 3 (2025), 633–639. doi:10.1152/advan.00253.2024
- [6] Alexandra Fiedler and Jörg Döpke. 2025. Do Humans Identify AI-Generated Text Better Than Machines? Evidence Based on Excerpts from German Theses. *International Review of Economics Education* (2025). doi:10.1016/j.iree.2025.100321
- [7] Lucas C. F. França et al. 2025. Um Estudo Sobre o Uso de Prompts LLM para a Avaliação de Acessibilidade Web. In *Proceedings of the Brazilian Symposium on Multimedia and the Web (WebMedia 2025)*.
- [8] Philipp Haindl and Gerald Weinberger. 2024. Does ChatGPT Help Novice Programmers Write Better Code? Results from Static Code Analysis. *IEEE Access* (2024). doi:10.1109/ACCESS.2024.3445432
- [9] Alexander A. Hernandez, Erlito M. Albina, and Arlene R. Caballero. 2025. Generative Artificial Intelligence for Programming Education: Enhancing Input to Outcome-Based Teaching and Learning Approaches. In *2025 7th International Symposium on Computer, Consumer and Control (IS3C)*. Taichung, Taiwan. doi:10.1109/IS3C65361.2025.11131023
- [10] Martin Jonsson and Jakob Tholander. 2022. Cracking the Code: Co-Coding with AI in Creative Programming Education. In *Proceedings of the 14th Conference on Creativity and Cognition (C&C '22)*. doi:10.1145/3527927.3532801
- [11] Gregor Jöst, Viktor Taneski, and Sašo Karakatič. 2024. The Impact of Large Language Models on Programming Education and Student Learning Outcomes. *Applied Sciences* (2024). doi:10.3390/app14104115
- [12] Enkelejda Kasneci, Kathrin Sessler, Stefan Küchemann, et al. 2023. ChatGPT for Good? On Opportunities and Challenges of Large Language Models for Education. *Learning and Individual Differences* (2023). doi:10.1016/j.lindif.2023.102274
- [13] Vassilka Kirova, Cyril Ku, Joseph Laracy, and Thomas Marlowe. 2024. Software Engineering Education Must Adapt and Evolve for an LLM Environment. In *Proceedings of the 55th ACM Technical Symposium on Computer Science Education V. 1 (SIGCSE 2024)*. doi:10.1145/3626252.3630927
- [14] Smitha S. Kumar, Michael Adam Lones, Manuel Maarek, and Hind Zantout. 2024. Investigating the Proficiency of Large Language Models in Formative Feedback Generation for Student Programmers. In *2024 IEEE/ACM International Workshop on Large Language Models for Code (LLM4Code)*. Lisbon, Portugal.
- [15] Sam Lau and Philip J. Guo. 2023. From “Ban It Till We Understand It” to “Resistance is Futile”: How University Programming Instructors Plan to Adapt as More Students Use AI Code Generation and Explanation Tools such as ChatGPT and GitHub Copilot. In *Proceedings of the 2023 ACM Conference on International Computing Education Research (ICER 2023)*. doi:10.1145/3568813.3600138
- [16] Rongxin Liu, Carter Zenke, Charlie Liu, Andrew Holmes, Patrick Thornton, and David J. Malan. 2024. Teaching CS50 with AI: Leveraging Generative Artificial Intelligence in Computer Science Education. In *Proceedings of the 55th ACM Technical Symposium on Computer Science Education (SIGCSE 2024)*. Portland, OR, USA. doi:10.1145/3626252.3630938
- [17] Carrie Philbin. 2023. Exploring the Potential of Artificial Intelligence Program Generators in Computer Programming Education for Students. *ACM Inroads* (2023). doi:10.1145/3610406
- [18] Alain Pinsonneault and Kenneth L. Kraemer. 1993. Survey Research Methodology in Management Information Systems: An Assessment. *Journal of Management Information Systems* (1993). doi:10.1080/07421222.1993.11518001
- [19] James Prather, Paul Denny, Juho Leinonen, Brett A. Becker, Ibrahim Albluwi, Michelle Craig, Hieke Keuning, Natalie Kiesler, Tobias Kohn, Andrew Luxton-Reilly, Stephen MacNeil, Andrew Petersen, Raymond Pettit, Brent N. Reeves, and Jaromir Savelka. 2023. The Robots Are Here: Navigating the Generative AI Revolution in Computing Education. In *Proceedings of the 2023 Working Group Reports on Innovation and Technology in Computer Science Education (ITiCSE-WGR '23)*. doi:10.1145/3623762.3633499
- [20] Savio Sampaio, Marcia Lima, Eriky Rodrigues, Maria Meireles, Marcela Sávia Picanço Pessoa, and Tayana Conte. 2024. Exploring the Use of Large Language Models in Requirements Engineering Education: An Experience Report with ChatGPT 3.5. In *Proceedings of the XXXVIII Brazilian Symposium on Software Engineering (SBES 2024)*. doi:10.1145/3701625.3701687
- [21] Paulo Roberto Dalla Valle and Jacques de Lima Ferreira. 2025. Análise de Conteúdo na Perspectiva de Bardin: Contribuições e Limitações para a Pesquisa Qualitativa em Educação. *Educação em Revista* (2025). doi:10.1590/0102-469849377
- [22] Tianjia Wang, Daniel Vargas-Diaz, Chris Brown, and Yan Chen. 2023. Exploring the Role of AI Assistants in Computer Science Education: Methods, Implications, and Instructor Perspectives. In *2023 IEEE Symposium on Visual Languages and Human-Centric Computing (VL/HCC 2023)*. doi:10.1109/VL-HCC57772.2023.00018
- [23] Jules White, Quchen Fu, Sam Hays, Michael Sandborn, Carlos Olea, Henry Gilbert, Ashraf Elnashar, Jesse Spencer-Smith, and Douglas C. Schmidt. 2023. A Prompt Pattern Catalog to Enhance Prompt Engineering with ChatGPT. In *Proceedings of the 30th Conference on Pattern Languages of Programs (PLoP '23)*.
- [24] Yuankai Xue, Hanlin Chen, Gina R. Bai, Robert Tairas, and Yu Huang. 2024. Does ChatGPT Help With Introductory Programming? An Experiment of Students Using ChatGPT in CS1. In *Proceedings of the 46th International Conference on Software Engineering: Software Engineering Education and Training (ICSE-SEET)*. ACM, 331–341. doi:10.1145/3639474.3640076
- [25] Cynthia Zastudil, Magdalena Rogalska, Christine Kapp, Jennifer Vaughn, and Stephen MacNeil. 2023. Generative Artificial Intelligence in Computing Education: Perspectives of Students and Instructors. In *2023 IEEE Frontiers in Education Conference (FIE 2023)*. doi:10.1109/FIE58773.2023.10343467
- [26] Benedikt Zönnchen, Martin Hobelsberger, Gudrun Socher, Veronika Thurner, and Sarah Ottinger. 2025. Exploring the Role of Large Language Models as Artificial Tutors. In *2025 IEEE Global Engineering Education Conference (EDUCON)*. London, United Kingdom. doi:10.1109/EDUCON62633.2025.11016571