

Transformações e Desafios da Docência em Programação no Brasil: O Papel dos Modelos de Linguagem de Grande Escala

ABSTRACT

The use of Large Language Models (LLMs) has transformed programming education, creating both opportunities and challenges for instructors and students. This study investigates programming instructors' perceptions of the use of these tools in programming courses. A qualitative study was conducted with ten instructors, and the interviews were analyzed using Bardin's Content Analysis. The results indicate that LLMs can support learning when used critically and appropriately, especially by students with a solid understanding of programming fundamentals. However, participants also highlighted risks related to dependency and reduced cognitive effort in introductory programming courses. In addition, methodological and assessment adaptations were identified, emphasizing authorship, logical reasoning, and critical thinking. As a distinguishing feature, this study includes instructors teaching both introductory and advanced programming courses.

KEYWORDS

Large Language Models, Generative Artificial Intelligence, Programming Education, Faculty Perceptions, Computing Education

1 INTRODUÇÃO

Com o surgimento da pandemia em 2019, estudantes e professores foram forçados a se adaptar a um novo formato de ensino. Nesse contexto, ocorreu também o lançamento público da tecnologia generativa em 2022 [20]. Com isso, a integração de Modelos de Linguagem de Grande Escala (LLMs) em diversos domínios revolucionou o cenário da inteligência artificial (IA) e do aprendizado de máquina (ML). No âmbito do processamento de linguagem natural, modelos baseados na arquitetura Transformer, como o ChatGPT (OpenAI) e o Copilot (Microsoft), demonstraram capacidades notáveis na compreensão e geração de textos semelhantes aos humanos [8].

Desse modo, além de sua capacidade de compreender e gerar linguagem natural, os Modelos de Linguagem de Grande Escala vêm sendo aplicados no contexto do ensino de programação, oferecendo suporte aos estudantes por meio do acesso a exemplos de código, explicações técnicas e auxílio no processo de depuração [8]. Sarsa [27] indica que essas ferramentas também oferecem benefícios relevantes para a prática docente na criação de materiais didáticos de programação. Embora os benefícios potenciais da utilização de Modelos de Linguagem

de Grande Escala (LLMs) no ensino de programação sejam evidentes, é fundamental compreender o impacto gerado em sala de aula, bem como as oportunidades, os desafios e as perspectivas decorrentes dessa adoção [31].

Um dos principais desafios atuais no ensino de programação consiste em compreender os impactos e as percepções dos docentes diante da adoção dos Modelos de Linguagem de Grande Escala (LLMs) nos processos de ensino e aprendizagem [32]. Alguns estudos publicados em 2023 passaram a investigar percepções de alunos e docentes no ensino de programação. No entanto, conforme destacado por Lau e Guo [13], diversos novos modelos e ferramentas de apoio à programação baseadas em inteligência artificial foram anunciados em um curto intervalo de tempo entre a submissão e a publicação do estudo, evidenciando a rapidez com que esse campo de pesquisa evolui. Nesse cenário de constantes avanços das LLMs, os resultados de estudos tendem a tornar-se obsoletos em um curto intervalo de tempo [20]. Além disso, observa-se que grande parte das investigações concentra-se na percepção discente, o que reforça a necessidade de estudos que aprofundem a compreensão das percepções dos docentes e de como o ensino de programação tem sido conduzido diante do advento das LLMs, lacuna que motiva o presente trabalho.

Portanto, este trabalho tem como objetivo investigar as perspectivas de docentes acerca do impacto do uso dos Modelos de Linguagem de Grande Escala (LLMs) em disciplinas de programação. A pesquisa adota uma abordagem qualitativa, baseada na realização de entrevistas semiestruturadas com professores que lecionam disciplinas de programação em diferentes níveis de formação. O roteiro de entrevistas foi elaborado a partir da literatura, visando garantir coerência teórica e aderência aos objetivos do estudo.

Com isso, espera-se compreender o impacto gerado pelos Modelos de Linguagem de Grande Escala (LLMs) e como o ensino de programação tem sido conduzido diante desse cenário, a partir da percepção de docentes experientes que atuaram como professores antes e após a popularização dessas tecnologias. Busca-se, ainda, contribuir de forma científica ao reunir percepções atuais de professores, possibilitando a identificação dos impactos proporcionados pelas LLMs no contexto educacional. Nesse contexto, espera-se compreender qual a melhor maneira de educadores se adaptarem a essas tecnologias em sala de aula e quais mudanças foram feitas ou estão sendo implementadas nesse novo momento, de modo a manter a qualidade do ensino de programação.

O presente estudo foi orientado pelas seguintes questões de pesquisa:

- **RQ1:** Quais são as percepções dos docentes de programação sobre o uso da IA generativa no processo de ensino e aprendizagem?
- **RQ2:** Quais benefícios e preocupações os docentes identificam no uso da IA generativa em suas disciplinas?
- **RQ3:** Como os docentes de programação têm adaptado suas práticas de avaliação após a popularização da IA generativa?
- **RQ4:** Quais desafios éticos os docentes percebem no uso de IA generativa no ensino de programação?

Os resultados obtidos contribuem para a compreensão dos impactos da IA generativa no ensino de programação sob a perspectiva docente, fornecendo evidências sobre benefícios, desafios, adaptações pedagógicas e práticas avaliativas adotadas em resposta ao uso crescente dessas tecnologias em disciplinas de programação. Além disso, os achados podem auxiliar pesquisadores, gestores educacionais e docentes na elaboração de estratégias para integrar ferramentas baseadas em Modelos de Linguagem de Grande Escala (LLMs) de forma ética e eficaz no contexto educacional no ensino de programação.

2 TRABALHOS RELACIONADOS

Xue et al. [34] investigaram o impacto do uso do ChatGPT no desempenho e no comportamento de estudantes em um curso introdutório de programação. Os resultados indicaram que, embora a ferramenta tenha contribuído para a redução do tempo necessário para a realização das atividades, não foram observadas melhorias significativas no desempenho acadêmico dos estudantes. Além disso, foi identificada uma diminuição no uso de recursos educacionais tradicionais, sugerindo maior dependência da ferramenta. Diferentemente desse estudo, que se concentra no contexto discente de disciplinas introdutórias, a presente pesquisa analisa as percepções docentes sobre o uso de LLMs em diferentes disciplinas de programação.

Lau e Guo [13] analisaram as percepções de instrutores de programação introdutória acerca do uso de ferramentas de IA generativa, como ChatGPT e GitHub Copilot. Os resultados evidenciaram preocupações relacionadas à integridade acadêmica e ao uso indevido dessas tecnologias, ao mesmo tempo em que apontaram oportunidades para sua integração pedagógica. Enquanto o estudo foi conduzido em disciplinas introdutórias, esta pesquisa amplia essa perspectiva ao considerar docentes que atuam também em disciplinas avançadas de programação.

Prather et al. [20] apresentaram uma revisão da literatura sobre o uso de LLMs no ensino de Computação, reunindo evidências provenientes de estudos recentes e de uma investigação envolvendo estudantes e docentes de diferentes países. Os autores destacam o crescente interesse da comunidade acadêmica na adoção dessas ferramentas e os desafios associados à sua utilização. Em contraste, o presente estudo concentra-se especificamente na percepção de docentes de programação sobre os impactos da IA generativa em suas práticas de ensino.

Kirova et al. [10] discutem a necessidade de adaptação do ensino de Engenharia de Software diante da crescente utilização de LLMs. Os autores defendem a valorização de competências conceituais, do pensamento crítico e da capacidade de avaliar artefatos produzidos por IA. Embora o estudo apresente recomendações relevantes para o contexto educacional, sua abordagem é predominantemente conceitual. Esta pesquisa complementa essa perspectiva ao investigar experiências e percepções de docentes em contextos reais de ensino.

Sampaio et al. [25] analisaram o uso do ChatGPT em atividades de elicitação de requisitos no contexto da Engenharia de Software. Os resultados demonstraram que a ferramenta pode contribuir para o desenvolvimento do raciocínio crítico dos estudantes quando utilizada de forma orientada, embora apresente limitações relacionadas à especificidade dos requisitos produzidos. Diferentemente desse trabalho, que avalia uma experiência prática com estudantes, a presente pesquisa investiga os desafios e oportunidades percebidos por docentes diante da incorporação de LLMs no ensino de programação.

Zastudil et al. [36] investigaram o uso de ferramentas de IA generativa no ensino de Computação por meio de entrevistas com estudantes e docentes. Os resultados apontaram oportunidades para apoio à geração de código e à aprendizagem, mas também evidenciaram preocupações relacionadas à avaliação, ao currículo e à integração pedagógica dessas tecnologias. Enquanto o estudo considera simultaneamente as perspectivas de estudantes e professores, esta pesquisa concentra-se exclusivamente na visão dos docentes de programação, buscando compreender como percebem os impactos da IA generativa em suas práticas pedagógicas e avaliativas.

3 FUNDAMENTAÇÃO TEÓRICA

3.1 Modelos de Linguagem de Grande Escala

Os modelos de linguagem de grande escala (LLMs) são modelos de aprendizado profundo treinados com grandes volumes de dados textuais, capazes de compreender e gerar linguagem natural, possibilitando a execução de tarefas como geração de texto, tradução automática e respostas a perguntas [6]. Modelos como a família GPT, o Gemini e o Claude vêm sendo amplamente adotados em diferentes contextos, incluindo o ensino, devido à capacidade de compreender e interagir de forma cada vez mais semelhante à linguagem humana [9].

3.2 LLMs no Ensino de Programação

O crescente interesse pelas ferramentas baseadas em Modelos de Linguagem de Grande Escala (*Large Language Models* – LLMs) no contexto educacional tem impulsionado investigações sobre seu potencial no ensino de programação. Ferramentas como ChatGPT, GitHub Copilot e Gemini demonstram capacidade de gerar código, responder dúvidas e revisar trechos existentes [16], atuando como suporte em um domínio que historicamente exige dos estudantes habilidades complexas de raciocínio lógico, abstração e resolução de problemas [30].

Do ponto de vista discente, essas ferramentas têm sido utilizadas como tutores virtuais, oferecendo explicações personalizadas, exercícios práticos e feedback imediato [12, 29?]. Estudos recentes com ChatGPT e DeepSeek no ensino de estruturas de dados em C [35] e de Python para iniciantes [14] indicam que as LLMs favorecem a compreensão de conceitos fundamentais, como sintaxe e funções, além de promoverem maior autonomia e engajamento dos estudantes. Sob a perspectiva docente, essas ferramentas contribuem para a elaboração de planos de aula, avaliações personalizadas e geração de exercícios [24, 27], reduzindo a sobrecarga associada à correção de atividades em turmas numerosas [28] e liberando tempo para atividades pedagógicas de maior complexidade. A análise de Pereira Filho et al. [18], realizada no contexto do ensino introdutório da linguagem C, reforça esse potencial ao registrar um aproveitamento superior a 80% nos exercícios desenvolvidos com o auxílio do ChatGPT.

Contudo, a adoção dessas ferramentas no ensino de programação também suscita preocupações relevantes. Um primeiro risco refere-se à qualidade das respostas geradas. As LLMs estão sujeitas a alucinações, isto é, à geração de informações incorretas, funções inexistentes ou bibliotecas inválidas [2, 5]. Conforme alertam Pereira Filho et al. [18], tais erros dificilmente são identificados por estudantes iniciantes, que tendem a aceitar as respostas sem uma avaliação crítica. Além disso, Lau et al. [13] destacam que o código gerado por IA pode apresentar desalinhamento em relação aos conteúdos trabalhados na disciplina, dificultando o processo de avaliação por parte do professor. Um terceiro risco, de natureza cognitiva, refere-se à dependência tecnológica. O uso contínuo das LLMs pode reduzir o estímulo à resolução autônoma de problemas [35]. Corroborando essa preocupação, Kosmyna et al. [11], em uma investigação baseada em eletroencefalografia (EEG) durante tarefas de escrita assistidas por IA, observaram menor engajamento cognitivo entre os participantes que utilizaram essas ferramentas. Além disso, estudantes iniciantes enfrentam uma curva de aprendizado para elaborar *prompts* eficazes, o que limita o aproveitamento das LLMs quando não há orientação adequada [33].

Em conjunto, essas evidências indicam que os benefícios das LLMs no ensino de programação dependem do nível de maturidade acadêmica dos estudantes e da mediação pedagógica realizada pelo professor. Assim, torna-se necessário investigar como docentes percebem e gerenciam os impactos dessas tecnologias em contextos reais de ensino, lacuna que o presente estudo se propõe a abordar.

3.3 Implicações na Integridade Acadêmica

As disciplinas de programação frequentemente demandam que os estudantes desenvolvam uma grande quantidade de exercícios práticos. Entretanto, muitos alunos enfrentam dificuldades tanto no planejamento quanto na implementação das soluções propostas, o que pode gerar frustração e comprometer o processo de aprendizagem. Nesse contexto, a pressão

para concluir atividades rapidamente pode favorecer comportamentos relacionados à desonestidade acadêmica, como a cópia de códigos e soluções de terceiros [21].

Alguns estudos apontam que a popularização das LLMs, como o Codex, altera significativamente a dinâmica da integridade acadêmica no ensino de programação. Diferentemente das práticas tradicionais de trapaga, que geralmente envolvem a cópia explícita de soluções ou a participação de terceiros, os sistemas de IA generativa oferecem respostas instantâneas, personalizadas e estruturalmente variadas. Isso reduz barreiras para o uso indevido dessas ferramentas e dificulta a identificação de comportamentos desonestos por métodos tradicionais de detecção de plágio [21].

Jones [7] classifica a desonestidade acadêmica em diferentes categorias. O plágio ocorre quando estudantes utilizam produções intelectuais de terceiros, por meio de cópia, paráfrase ou imitação, sem o devido reconhecimento da fonte, apresentando o conteúdo como se fosse de autoria própria. O conluio caracteriza-se pela colaboração não autorizada entre estudantes, ou entre estudantes e terceiros, em atividades apresentadas como trabalho individual, incluindo situações em que um aluno permite que sua produção seja atribuída a outro estudante. A falsificação ocorre quando informações, conteúdos ou resultados são inventados ou apresentados de maneira enganosa como produções autênticas. Por fim, as fraudes em avaliações abrangem o uso de materiais ou dispositivos não autorizados durante provas, a obtenção indevida de cópias de exames e a personificação ou falsidade de identidade em situações avaliativas.

Orenstrakh et al. [17] associam o uso de ferramentas de IA generativa ao plágio. Entretanto, outros estudos argumentam que o conteúdo produzido por esses sistemas ocorre de maneira semelhante ao processo de escrita humana, no qual diferentes referências e materiais prévios são utilizados para gerar novas produções textuais [20]. Nessa perspectiva, o estudante que utiliza ferramentas de IA generativa pode ser considerado o autor do trabalho produzido, uma vez que é responsável por direcionar e utilizar os resultados gerados pelo sistema. Nesse sentido, Samuelson [26] argumenta que “o usuário responsável pela geração das saídas deve ser considerado o autor”. Contudo, em situações raras, ferramentas de IA podem reproduzir integralmente conteúdos já existentes, o que configuraria efetivamente casos de plágio [20].

4 METODOLOGIA

A pesquisa adotada no presente estudo se caracteriza como qualitativa, de natureza descritiva e exploratória. Exploratória, pois busca compreender um fenômeno ainda recente, relacionado ao uso de Modelos de Linguagem de Grande Escala (LLMs) no ensino de programação no Brasil, permitindo maior familiaridade com o tema a partir das percepções de docentes que atuam na área. Descritiva, por apresentar e organizar as características, opiniões e experiências desses docentes, sem a interferência do pesquisador no contexto investigado [19].

Nesse caminho, a pesquisa foi conduzida por meio de um estudo empírico baseado na realização de entrevistas semiestruturadas, complementadas pela aplicação de um questionário. A partir dessa abordagem, foram definidos os procedimentos de coleta de dados, de modo a possibilitar a obtenção de informações detalhadas sobre as percepções dos docentes. Para isso, foram utilizados técnicas específicas, descritos na subseção a seguir.

4.1 Instrumento de Coleta de dados

A coleta de dados foi realizada por meio de entrevistas semiestruturadas em profundidade, técnica que permite conciliar a liberdade de expressão dos participantes com a condução orientada pelo pesquisador, mantendo o foco nos objetivos da investigação. Duarte [4] destaca que esse tipo de entrevista é particularmente adequado para estudos que buscam compreender fenômenos complexos a partir das experiências e percepções dos sujeitos investigados.

A Figura 1 resume as etapas adotadas para a construção dos instrumentos de coleta. Inicialmente, foi conduzida uma revisão de literatura exploratória nas bases IEEE, Scopus e ACM, combinando termos relacionados a educação em programação, IA generativa, atuação docente e métodos qualitativos, complementada pela técnica de *snowballing*.

Três estudos da literatura foram utilizados como principal referência para a definição das dimensões investigadas e dos critérios de inclusão dos participantes. Esses estudos estão apresentados na Tabela 1.

Table 1: Estudos de referência para a elaboração dos instrumentos.

Autor(es)	Título	Ano
Prather et al.	The Robots Are Here: Navigating the Generative AI Revolution in Computing Education	2023
Wang et al.	Exploring the Role of AI Assistants in CS Education: Methods, Implications, and Instructor Perspectives	2023
Lau e Guo	“Ban It Till We Understand It” to “Resistance is Futile”: How Instructors Plan to Adapt to AI Code Generation Tools	2023

5 ROTEIRO DE ENTREVISTA

Para avaliar a adequação do roteiro de entrevista, foram realizados dois procedimentos: uma entrevista piloto e a análise das ações verbais presentes nas questões, conforme proposto por Manzini [15].

A entrevista piloto foi realizada com dois docentes de programação, com o objetivo de verificar a clareza, a pertinência e o grau de compreensão das questões pelos participantes, bem como identificar eventuais problemas de formulação que pudessem comprometer a coleta de dados. A partir dos resultados obtidos nessa etapa, o roteiro foi revisado e ajustado, com reformulação de questões que se mostraram ambíguas ou redundantes. Em consonância com as recomendações metodológicas para a realização de estudos piloto, os

dois docentes que participaram dessa etapa preliminar foram excluídos da amostra final da pesquisa, de modo a evitar viés decorrente do contato prévio com uma versão não definitiva do instrumento.

O roteiro original foi composto por 26 questões, elaboradas com base na literatura e nos objetivos da pesquisa. A análise das ações verbais permitiu verificar se as intenções do pesquisador estavam alinhadas aos objetivos de cada pergunta e ao tipo de resposta esperado dos participantes [3]. Como exemplo, a questão "Qual é a sua percepção do uso de IA/LLM em atividades propostas pelos alunos de programação na sua disciplina?" foi elaborada para identificar as percepções docentes sobre o uso dessas tecnologias no contexto educacional.

Devido às limitações de espaço deste artigo, a Tabela 2 apresenta apenas algumas questões representativas do roteiro de entrevista semiestruturado, relacionando-as aos respectivos temas e objetivos investigados. Essa síntese ilustra a estrutura do instrumento de coleta de dados, preservando sua organização metodológica.

6 PERFIL DOS DOCENTES

Foram incluídos docentes brasileiros da área de Computação com experiência em disciplinas de programação e que tivessem atuado tanto antes quanto após a popularização das LLMs; foram excluídos professores sem essa vivência comparativa ou com menos de um ano de experiência docente. Participaram do estudo dez docentes vinculados a cursos de Computação, com experiência entre 5 e mais de 10 anos no ensino de programação, atuando em disciplinas como Lógica de Programação, Programação Orientada a Objetos, Estrutura de Dados e Banco de Dados, entre outras. Os participantes estão distribuídos nos estados do Ceará (6), Minas Gerais (2), São Paulo (1) e Piauí (1).

7 PROCEDIMENTO DE COLETA DE DADOS

Após a elaboração do roteiro de entrevista, iniciou-se a etapa de coleta de dados. O recrutamento dos docentes foi realizado por meio de convites enviados por e-mail, seguido do agendamento das entrevistas com cada participante.

A coleta de dados ocorreu em três etapas: inicialmente, foi apresentado o Termo de Consentimento Livre e Esclarecido (TCLE); em seguida, foram realizadas as entrevistas com base em um roteiro semiestruturado; por fim, foi aplicado um formulário.

7.1 Termo de consentimento livre e esclarecido (TCL)

Documento de caráter formal estabelecido entre a pesquisadora e cada participante, no qual são apresentadas informações sobre os objetivos da pesquisa, os procedimentos adotados e a forma de condução do estudo. O termo também contempla a autorização para o uso dos dados coletados, assegurando o anonimato dos participantes.

O Termo de Consentimento Livre e Esclarecido foi apresentado e lido no momento inicial da entrevista, sendo a



Figure 1: Estratégia para construção do roteiro de entrevista.

Table 2: Questões representativas do roteiro de entrevista semiestruturada.

Questão	Tema	Objetivo
Qual é a sua percepção do uso de IA/LLM em atividades propostas pelos alunos de programação na sua disciplina?	Uso de IA na educação	Compreender as percepções docentes sobre o uso de LLMs no ensino de programação.
Na sua percepção, a qualidade da aprendizagem dos alunos com o advento da IA melhorou ou piorou?	Qualidade da aprendizagem	Investigar os impactos percebidos da IA no processo de aprendizagem.
Como você percebe o impacto dos LLMs no desenvolvimento de habilidades de raciocínio lógico e resolução de problemas?	Desenvolvimento cognitivo	Analisar a influência das LLMs no desenvolvimento de competências cognitivas.
Como você está lidando com atividades de programação para evitar respostas diretamente fornecidas por IA?	Estratégias docentes	Identificar adaptações pedagógicas adotadas pelos docentes.
Você planeja mudar o mecanismo de avaliação?	Avaliação da aprendizagem	Investigar mudanças nas estratégias de avaliação após a popularização das LLMs.
Você acredita que o papel do professor de programação está mudando com o avanço dos LLMs? Se sim, como?	Futuro da docência	Compreender as transformações percebidas na atuação docente.

autorização dos participantes devidamente registrada por meio de gravação. Além disso, foi garantido aos participantes o direito de interromper sua participação a qualquer momento, sem qualquer tipo de prejuízo.

7.2 Entrevista com Docente

Utilizou-se o roteiro semiestruturado para a condução das entrevistas, conforme apresentado na Tabela 3. As entrevistas foram programadas para durar entre 20 e 45 minutos. Na prática, a maioria teve duração próxima de 50 minutos. Elas foram conduzidas via Google Meet, com permissão para gravação, e posteriormente transcritas automaticamente por meio de um software de reconhecimento de fala, seguido de verificação e correção humana (a entrevistadora realizou a revisão manual das transcrições nos casos de falas não compreendidas ou mal transcritas).

7.3 Aplicação do Questionário

A aplicação do questionário foi realizada após a condução das entrevistas. O instrumento foi composto por dez questões destinadas à caracterização dos participantes e à coleta de

informações complementares relevantes para a pesquisa. O questionário foi disponibilizado aos docentes por meio de um link encaminhado após a realização da entrevista.

Participaram do estudo dez docentes que atenderam aos critérios de inclusão previamente estabelecidos e concordaram voluntariamente em participar da pesquisa.

8 PREPARAÇÃO E ANÁLISE DOS DADOS

A técnica de Análise de Conteúdo de Bardin foi utilizada, adotando-se a modalidade de análise temática. Esse método possibilita a organização, codificação e interpretação de dados qualitativos, permitindo identificar padrões e categorias nos discursos dos participantes. Conforme Bardin [1], a análise foi conduzida em três etapas: pré-análise, exploração do material e tratamento dos resultados, inferência e interpretação. A Tabela 3 apresenta uma síntese das atividades realizadas em cada etapa.

8.1 Pré-análise

Na pré-análise, as entrevistas foram transcritas, revisadas e organizadas para compor o corpus da pesquisa. Em seguida,

Table 3: Etapas da Análise de Conteúdo adotadas na pesquisa.

Etapa	Objetivo	Procedimentos realizados
Pré-análise	Organizar e preparar o corpus da pesquisa.	Transcrição das entrevistas, conferência dos registros e leitura flutuante para organização e familiarização com o corpus.
Exploração do material	Codificar e categorizar os dados.	Segmentação das falas em unidades de registro, codificação e agrupamento em categorias temáticas.
Tratamento dos resultados, inferência e interpretação	Organizar os resultados, re-alizar inferências e interpretar os dados.	Consolidação das categorias, enumeração das unidades de registro por frequência de ocorrência, discussão dos resultados à luz do referencial teórico e interpretação dos achados.

foi realizada a leitura flutuante do material, com o objetivo de familiarização com os dados e identificação de elementos relevantes para a investigação, conforme proposto por Bardin [1].

8.2 Exploração do Material

Na etapa de exploração do material, as transcrições foram analisadas por meio de codificação temática. Inicialmente, foram identificadas unidades de registro relacionadas às percepções, experiências, desafios e estratégias docentes acerca do uso da IA generativa no ensino de programação. Em seguida, os códigos foram agrupados por similaridade, resultando na definição de categorias e subcategorias analíticas utilizadas na interpretação dos resultados. A Tabela 4 apresenta as categorias e subcategorias identificadas durante a análise, enquanto a Tabela 5 apresenta os principais códigos associados a essas categorias.

As principais categorias identificadas para responder as questões de pesquisa foram: (i) percepção e diagnóstico inicial do uso da IA; (ii) impactos na aprendizagem; (iii) estratégias de adaptação docente; (iv) impacto cognitivo e dependência; e (v) ética, detecção e políticas institucionais. Essas categorias serviram de base para a análise dos resultados e para a resposta às questões de pesquisa.

8.3 Tratamento dos Resultados, Inferência e Interpretação

Após a codificação das entrevistas, realizou-se a enumeração das unidades de registro por frequência de ocorrência, conforme proposto por Bardin [1]. Para cada código, foi contabilizado o número de docentes que o mencionaram e calculada sua frequência relativa em porcentagem ($f\%$), considerando o total de participantes da pesquisa. Essas frequências foram utilizadas como apoio à análise qualitativa, permitindo identificar os temas mais recorrentes e subsidiar a interpretação

dos resultados. Posteriormente, os achados foram analisados e discutidos à luz do referencial teórico adotado, buscando compreender como os docentes percebem os impactos da IA generativa no ensino de programação e as estratégias empregadas para lidar com esse fenômeno.

9 RESULTADO E DISCUSSÃO

Esta seção apresenta os resultados obtidos a partir das entrevistas com os docentes participantes. Os achados foram organizados conforme as questões de pesquisa que orientam o estudo (RQ1 a RQ4) e discutidos à luz do referencial teórico, permitindo relacionar as evidências empíricas aos estudos da área. Complementarmente, são apresentados gráficos de frequência dos códigos identificados durante a análise.

9.1 Percepções docentes sobre o uso de LLMs no ensino de programação (RQ1)

Os resultados indicam que o uso de ferramentas baseadas em LLMs nas disciplinas de programação já constitui uma realidade consolidada no cotidiano dos estudantes, sendo percebido de forma consistente pelos dez docentes participantes. Esse achado converge com Zastudil et al. [36], que apontam que ferramentas baseadas em inteligência artificial estão cada vez mais presentes no ensino, modificando as dinâmicas de aprendizagem. Os relatos evidenciam que o desafio atual deixou de ser a presença das LLMs em sala de aula e passou a ser a forma como essas ferramentas são utilizadas pelos estudantes. Embora alguns docentes ainda estejam em processo de adaptação às mudanças provocadas por essas tecnologias, outros já relataram alterações em suas práticas pedagógicas, indicando que a incorporação das LLMs ao ensino constitui um processo em evolução.

Um aspecto que emergiu com particular consistência nas entrevistas foi a distinção entre dois modos de utilização das LLMs. O primeiro corresponde ao uso orientado à aprendizagem, no qual a ferramenta é empregada para esclarecer dúvidas, explorar diferentes estratégias de resolução e ampliar a compreensão dos conteúdos. O segundo refere-se ao uso indiscriminado, caracterizado pela delegação da resolução da atividade à ferramenta e pela utilização do resultado gerado sem interpretação ou validação crítica. Essa percepção é sintetizada por D1:

“Acredito que os alunos utilizem bastante atualmente. Inclusive, recomendo que utilizem; no entanto, saber utilizá-las para auxiliar no entendimento é muito diferente de simplesmente solicitar que uma LLM execute uma determinada tarefa e pegar o resultado gerado sem interpretar aquilo.”
(D1)

Outro aspecto recorrente nas entrevistas foi a percepção das LLMs como uma espécie de “tutor permanente”, disponível para esclarecer dúvidas, fornecer exemplos e apoiar os estudantes durante a resolução de problemas. Nessa perspectiva, os docentes reconhecem o potencial das ferramentas para oferecer suporte contínuo ao aprendizado fora do ambiente de sala de aula. Essa visão é ilustrada por D8:

Table 4: Categorias e subcategorias resultantes da análise temática.

Categoria	Descrição	Subcategorias
CAT. 1	Percepção e diagnóstico inicial do uso	1.1 IA como ferramenta de aprendizagem potencial; 1.2 Uso inadequado e dependência; 1.3 Maturidade acadêmica como variável moderadora.
CAT. 2	Impacto na qualidade da aprendizagem	2.1 Polarização de desempenho; 2.2 Qualidade e autoria das entregas; 2.3 Raciocínio lógico e autonomia intelectual.
CAT. 3	Estratégias de adaptação docente	3.1 Reformulação das avaliações; 3.2 Incentivo ao uso crítico e orientado; 3.3 Papel institucional e perspectiva histórica.
CAT. 4	Impacto cognitivo e dependência	4.1 Dependência cognitiva gerada pelo uso irrestrito; 4.2 Mascaramento das dificuldades iniciais; 4.3 Uso maduro como contraponto positivo.
CAT. 5	Ética, detecção e políticas institucionais	5.1 Estratégias éticas no uso das LLMs; 5.2 Detecção e manejo do uso indevido; 5.3 Políticas institucionais: lacuna percebida.
CAT. 6	Adaptações metodológicas e avaliativas	6.1 Integração intencional das LLMs nas atividades; 6.2 Substituição de formatos avaliativos; 6.3 IA como apoio ao trabalho docente.

“Eles deveriam pedir uma explicação, pedir um exemplo, usar como se fosse um tutor, um professor, 24 horas para eles. É o que eu penso, mas não é o que eu noto que eles fazem.” (D8)

A mesma percepção aparece na fala de D7:

“Eu não acho que a gente vai perder nesse sentido, porque a gente vai passar a oferecer para esses alunos uma possibilidade de ter um suporte 24 horas, de como aprender.” (D7)

Outro resultado relevante refere-se à postura adotada pelos docentes diante da disseminação dessas ferramentas. Diferentemente dos achados de Lau e Guo [13], que identificaram entre docentes de programação a adoção de políticas restritivas para o uso dessas tecnologias, nenhum dos participantes desta pesquisa defendeu a proibição das LLMs. Ao contrário, prevaleceu a compreensão de que seu uso deve ser planejado, orientado e integrado às práticas pedagógicas de forma crítica, privilegiando estratégias que promovam autoria, reflexão e aprendizagem ativa. Essa posição é ilustrada pela fala de D2:

“Proibir, às vezes, só dá uma ideia do aluno ir atrás daquilo. Então, ele não faz no computador que está utilizando na aula, mas faz uso no celular. Entender até que ponto ele está fazendo de forma correta é mais importante do que proibir.” (D2)


A mesma perspectiva aparece na fala de D7:

“Sempre acho que deve ser permitido. Só que eu acho que tem que ser planejado. De maneira planejada sempre é útil. Sempre vai ser útil. Desde que seja planejado nunca vai ser problema, na minha concepção.” (D7)

Esses resultados estão alinhados às recomendações de Qadir [22], que defendem a integração crítica das ferramentas de IA ao ensino em vez de sua proibição. Os resultados

desta pesquisa sugerem que, na percepção dos participantes, a mediação pedagógica representa uma resposta mais efetiva do que a proibição diante de uma tecnologia já incorporada ao cotidiano dos estudantes.

A Figura 2 apresenta a frequência de ativação dos códigos associados à RQ1, evidenciando as percepções dos docentes acerca do uso de LLMs no contexto educacional. Os códigos foram agrupados em duas categorias analíticas: *Aprendizagem Potencial* e *Uso das Ferramentas*.


Figure 2: Frequência de ativação dos códigos associados à RQ1.

A Figura 2 apresenta a frequência de ativação dos códigos associados à RQ1, obtida por meio da análise de conteúdo segundo Bardin. Observa-se que os códigos foram organizados em três grupos temáticos: *Aprendizagem Potencial*, *Uso Inadequado* e *Maturidade Acadêmica*, sintetizando as principais percepções dos docentes sobre o uso das LLMs no ensino de

Table 5: Exemplos de códigos identificados durante a análise temática.

Cat.	Subcategoria	Exemplos de códigos
1.1	IA como ferramenta de aprendizagem potencial	Uso consciente e orientado; IA como tutor permanente; suporte ao aprendizado contínuo.
1.2	Uso inadequado e dependência	Uso indiscriminado sem avaliação crítica; dependência e redução da iniciativa; delegação do raciocínio à IA.
2.1	Polarização de desempenho	Potencialização dos bons alunos; manutenção da proporção entre perfis; piora para alunos passivos.
2.2	Qualidade e autoria das entregas	Entregas corretas sem autoria real; superficialidade do conteúdo produzido; velocidade aumentada e profundidade reduzida.
2.3	Raciocínio lógico e autonomia intelectual	Risco à criatividade; raciocínio lógico como habilidade central; preguiça cognitiva.
3.1	Reformulação das avaliações	Migração para avaliações presenciais; avaliação do processo; impossibilidade de exercícios domiciliares.
3.2	Incentivo ao uso crítico e orientado	Estímulo com responsabilidade pedagógica; validação de fontes; uso moderado como suporte.
5.1	Estratégias éticas no uso das LLMs	Transparência e autoria; propriedade intelectual; referências bibliográficas inexistentes.
5.2	Deteção e manejo do uso indevido	Indícios de geração por IA; uso de estruturas não ensinadas; conversa individual com o estudante.
4.1	Dependência cognitiva gerada pelo uso irrestrito	Substituição do esforço pelo resultado imediato; perda da capacidade de resolver sem a ferramenta; dependência comparada a outras tecnologias.
4.2	Mascaramento das dificuldades iniciais	IA ocultando lacunas de raciocínio nos iniciantes; ansiedade e imediatismo como agravantes; lógica e estrutura de dados como disciplinas sensíveis.
4.3	Uso maduro como contraponto positivo	Ampliação de repertório em alunos avançados; IA como parceiro em contextos aplicados; nicho técnico como limitador natural da dependência.
6.1	Integração intencional das LLMs nas atividades	IA como objeto de análise crítica pelo aluno; avaliação do prompt como evidência de raciocínio; IA com respostas erradas como recurso pedagógico.
6.2	Substituição de formatos avaliativos	Substituição de trabalhos escritos por apresentações; uso de vídeo e áudio como alternativa; avaliação em papel como blindagem à IA.
6.3	IA como apoio ao trabalho docente	Uso pelo professor na preparação de aulas; ganho de tempo para aprofundamento pedagógico; geração de dinâmicas e conteúdos novos.

programação. Na categoria *Aprendizagem Potencial*, o código *Consciente* apresentou frequência de ativação em todos os relatos analisados (100%), indicando consenso entre os participantes quanto à necessidade de um uso crítico e reflexivo das LLMs. Também se destacaram os códigos *Aprendizado* (80%) e *Tutor IA* (70%), evidenciando que os docentes reconhecem nessas ferramentas potencial para apoiar o processo de aprendizagem e auxiliar estudantes em diferentes atividades acadêmicas.

Na categoria *Uso das Ferramentas*, os códigos *Indiscriminado* (90%) e *Delegação* (90%) apresentaram as maiores frequências de ativação. Esses resultados indicam que os docentes observam um uso frequente das LLMs pelos estudantes para a realização de atividades acadêmicas, muitas vezes transferindo parte significativa da execução das tarefas para as ferramentas. Os códigos *Dependência* (70%), *Prejudicial* (60%) e *Qualificado* (50%) também foram identificados

nos relatos, evidenciando que os participantes percebem diferentes formas de utilização das LLMs, associadas a distintos níveis de envolvimento dos estudantes com as atividades propostas.

De modo geral, os resultados mostram que os docentes percebem as LLMs como tecnologias já incorporadas ao cotidiano acadêmico dos estudantes de programação. Os participantes reconhecem tanto o potencial dessas ferramentas como recurso de apoio quanto a existência de diferentes padrões de utilização, que variam em função da forma como os estudantes interagem com os sistemas de IA generativa. Essas percepções iniciais fornecem uma visão geral sobre a presença e o uso das LLMs no ensino de programação, servindo de base para a análise dos possíveis efeitos dessa utilização no desenvolvimento acadêmico dos estudantes, apresentada na RQ2.

9.2 Benefícios e Preocupações Associados ao Uso de LLMs (RQ2)

Maturidade Acadêmica como Variável Moderadora. Os relatos dos docentes convergem para um ponto central: os impactos das LLMs não são uniformes, mas modulados pelo nível de maturidade acadêmica dos estudantes. Esse resultado encontra respaldo quantitativo na categoria *Maturidade Acadêmica* na Figura 2, na qual o código *Prejudicial* apresentou a maior frequência de ativação (80%), concentrada nas disciplinas introdutórias. O código *Qualificado* (70%) reflete, por sua vez, os benefícios relatados em disciplinas avançadas, nas quais os estudantes já possuem base conceitual consolidada para validar e utilizar criticamente as respostas da IA.

Nas disciplinas iniciais, os docentes identificaram dois fatores que agravam esse risco: a ausência de repertório para avaliar a plausibilidade das respostas geradas e a imediatez com que os estudantes abandonam a tentativa autônoma de resolução. D6 articulou essa distinção de forma direta:

“Para disciplinas de programação mais avançadas, eu acredito que o uso da IA possa ser interessante. Só que nas disciplinas iniciais eu tenho dificuldades para considerar isso válido. Porque, no primeiro período, o aluno nunca teve contato com programação e muitos têm dificuldade em exercitar a lógica. Se ele vai exercitar isso com uma ferramenta de IA, ele delega tudo para a IA, não consegue pensar como ela gerou, só fala que deu resultado certo e vai entregar. A grande parcela dos alunos acabou de sair do ensino médio e não tem maturidade suficiente para distinguir que isso está mais prejudicando do que auxiliando. Mas, a partir do momento que ele entende muito bem, eu não vejo problema algum.” (D6)

D8 acrescentou que a ansiedade dos estudantes intensifica esse comportamento nas disciplinas iniciais, nas quais a paciência para enfrentar o problema é, em si, uma competência a ser desenvolvida:

“Os alunos estão mais imediatistas em querer passar menos tempo em um mesmo problema. Então, eles acabam perdendo a paciência e pedindo para a IA resolver para eles. É melhor o aluno descobrir por conta própria como construir um algoritmo do que simplesmente pedir uma solução pronta. Os alunos do primeiro semestre que estão aprendendo, ela é ruim. Ela está influenciando negativamente. Os alunos que já têm uma base muito sólida e que querem avançar mais, ela é excelente.” (D8)

Esse risco, descrito como particularmente acentuado nos contextos introdutórios, é convergente com os achados de Pereira Filho et al. [18]. O código *Comparação* (40%) na Figura 2 reflete exatamente esses relatos que contrastam o uso das LLMs em diferentes etapas da formação, reforçando que a questão não é proibir ou liberar irrestritamente, mas compreender em que condições o uso é pedagogicamente produtivo.

Nesse sentido, os docentes não chegaram a um consenso sobre a necessidade de restringir o acesso às LLMs em disciplinas introdutórias, situação semelhante à tensão observada por Lau e Guo [13]. Uma parte dos participantes defendeu limitações nesse contexto; outra ressaltou que a integração orientada pode favorecer aprendizagens mais reflexivas. D7 exemplificou como o professor pode mediar esse uso em vez de simplesmente barrá-lo:

“O professor pode estimular, ao invés de criar uma barreira, ele pode criar uma lista de perguntas para ser feitas para a IA. Olha, vou te dar aqui uma lista de perguntas que você vai fazer para a IA e eu quero que você me traga as respostas. E aí, com base nas respostas, o professor pode propor um exercício em sala sem computador. Não dá para fugir disso, mas eu acho que ela pode, inclusive, se adaptar ao jeito do aluno.” (D7)

D8 reforçou que a resposta adequada não consiste na proibição dessas ferramentas, mas na reconfiguração das metodologias de ensino, com a transferência das atividades práticas para a sala de aula e do conteúdo teórico para o estudo autônomo, enquanto a IA assume o papel de tutor remoto:

“Não dá para proibir. É só tentar trabalhar a conscientização e, principalmente na sala de aula, trabalhar com metodologias mais ativas, colocar o aluno como dono do próprio processo. [...] O aluno tendo a IA como um tutor, como um professor remoto, é uma excelente oportunidade de aperfeiçoar o ensino de programação.” (D8)

Impacto Cognitivo e Dependência. O efeito mais consistentemente relatado pelos docentes foi a polarização do desempenho dos estudantes. Em vez de reduzir as diferenças de desempenho entre os estudantes, as LLMs parecem amplificar características acadêmicas preexistentes: estudantes já engajados utilizam as ferramentas para expandir conhecimentos e explorar novas abordagens de resolução de problemas, enquanto estudantes com menor comprometimento recorrem a elas como atalho, sem avaliar criticamente os resultados produzidos. D5 sintetizou essa percepção:

“Os bons alunos, eles foram potencializados [...]. Agora, para o aluno que [...] simplesmente coloca na ferramenta, a ferramenta posta ali o resultado e ele não consegue às vezes nem interpretar se aquele resultado está correto [...]. Acho que piorou a situação dele.” (D5)

Esse padrão é compatível com o que Tang et al. [31] descrevem como dependência excessiva das LLMs, que exige supervisão contínua para validação das respostas produzidas. Os relatos indicam que essa dependência afeta principalmente estudantes que já apresentavam dificuldades ou menor engajamento, sugerindo que os efeitos educacionais das LLMs dependem não apenas da tecnologia em si, mas das estratégias de aprendizagem de cada estudante.

“Quando a gente está analisando a escrita [...], com muita facilidade a gente consegue discernir.”

Até essa página, foi uma pessoa que escreveu; a partir dessa página é outro estilo de escrita. [...] Hoje é rápido, quase sem erro, e aquele trabalho que a gente percebe que foi realizado no LLM, de forma equivocada [...] prejudica, porque no final das contas o aluno fica ali, atrapalha o processo de aprendizado e acaba atrapalhando não só ele, a instituição também, na hora de uma avaliação.” (D10)

Essa dissociação evidencia um risco que vai além do desempenho imediato: o estudante pode concluir atividades com aparente sucesso sem desenvolver as competências cognitivas subjacentes. Raciocínio lógico e autonomia intelectual foram apontados pelos docentes como as capacidades mais ameaçadas por esse uso acrítico, perspectiva convergente com Souleiman et al. [30], que destacam que a aprendizagem de programação depende de prática contínua, reflexão e enfrentamento de desafios progressivos. D9 resumiu a preocupação:

“A principal ferramenta de vocês, enquanto futuros trabalhadores da computação, é a capacidade de resolver problemas. É o seu raciocínio, é a sua capacidade de abstração, é o raciocínio lógico. [...] Quem tem que pensar é o estudante.” (D9)

A gravidade dessa dependência torna-se concreta em um relato de D9 sobre um ex-aluno que atua como tutor em uma empresa de tecnologia. A situação ilustra como a delegação sistemática à IA pode resultar na perda progressiva da capacidade de resolver problemas de forma autônoma:

“Ele me disse que o pessoal tá muito viciado em usar o ChatGPT para resolver os problemas e acabam desaprendendo a programar. Certo dia eu peguei um bolsista nosso e estava vendo ele fazer isso recorrentemente. Todo problema que ele ia resolver, primeiro levantava o ChatGPT. Aí eu disse assim: vamos fazer o seguinte, tenta resolver sem o ChatGPT. Aí o cara olhou para mim e disse: eu não consigo. Então é melhor eu te dispensar e ficar só com o ChatGPT. Porque, se fosse para usar o ChatGPT, eu não teria você aqui. Você começa a ficar com o raciocínio preguiçoso. Use, mas use com moderação. Não vá delegar tudo; que sempre tenha pensamento crítico.” (D9)

Esse relato vai além de um caso isolado: ele aponta para uma consequência estrutural do uso irrestrito das LLMs no mercado de trabalho. O profissional que delega sistematicamente o raciocínio à ferramenta perde não apenas a habilidade técnica, mas também a capacidade de avaliar a qualidade das respostas geradas, aspecto que Kosmyna et al. [11] associam ao menor engajamento cognitivo decorrente do uso contínuo de ferramentas de IA.

A Figura 3 apresenta a frequência de ativação dos códigos associados à RQ2, obtida a partir da análise de conteúdo segundo Bardin. Observa-se que o código *Raciocínio lógico* como habilidade central e insubstituível apresentou a maior frequência de ativação (100%), seguido por *Piora para alunos*




Figure 3: Frequência de ativação dos códigos associados à RQ2.

passivos (90%). Também se destacaram os códigos *Potencialização dos bons alunos*, *Entregas corretas sem autoria real* e *Preguiça cognitiva* como risco central, todos com frequência de 80%. Em contrapartida, os códigos *Velocidade aumentada*, *profundidade reduzida* (60%) e *Manutenção da proporção entre perfis* (30%) apresentaram menor recorrência entre os participantes. Esses resultados evidenciam que as principais preocupações dos docentes concentram-se nos impactos das LLMs sobre o raciocínio lógico, a autonomia intelectual e a qualidade da aprendizagem dos estudantes.

Benefícios das LLMs em contextos avançados de aprendizagem. À medida que a maturidade acadêmica aumenta, os riscos associados ao uso das LLMs tendem a diminuir e os benefícios tornam-se mais evidentes. Os relatos dos docentes indicam que estudantes com maior domínio conceitual conseguem utilizar essas ferramentas de forma mais estratégica, explorando seus recursos para ampliar conhecimentos, desenvolver projetos mais sofisticados e aprofundar a aprendizagem.

D8 relatou que, para estudantes envolvidos em maratonas e olimpíadas de programação, as LLMs desempenham um papel importante na ampliação do repertório teórico:

“Para alunos de maratona de programação, de olimpíadas de programação, aí já é o contrário. [...] A IA é espetacular porque ela ajuda o aluno a ter repertório. Ela é muito boa em trazer algoritmos já conhecidos e explicar esses algoritmos. Então, ela dá para o aluno a possibilidade de aumentar o repertório dele.” (D8)

Esse resultado converge com estudos que descrevem as LLMs como tutores virtuais capazes de fornecer explicações, exemplos e suporte personalizado à aprendizagem [12? ?]. Nesses contextos, a ferramenta não substitui o processo de aprendizagem, mas amplia o acesso a conhecimentos, algoritmos e estratégias de resolução de problemas que podem ser explorados pelos estudantes de forma autônoma.

Além do apoio conceitual, os docentes observaram benefícios relacionados ao desenvolvimento de software. D4 destacou que os estudantes utilizam as LLMs para acelerar tarefas de implementação, revisão e refinamento de código:

“Utilizam bastante para criação rápida de código, melhoria de alguns códigos, utilização para transformar mockups visuais em código testável.” (D4)

O docente também observou que as ferramentas passaram a ser utilizadas como suporte complementar em diferentes etapas do desenvolvimento:

“Muitas vezes eles criam o front-end eles mesmos [...] e depois usam a ferramenta para a montagem do back-end.” (D4)

Esses relatos corroboram a literatura que aponta que as LLMs podem acelerar o desenvolvimento de software por meio da geração de código, sugestões de implementação e auxílio na resolução de problemas computacionais [2]. Nesse cenário, as ferramentas passam a atuar como assistentes de desenvolvimento, permitindo que os estudantes concentrem esforços em atividades de maior complexidade e reduzam o tempo dedicado a tarefas mais operacionais.

Outro benefício identificado pelos docentes refere-se ao uso das LLMs como parceiras de programação durante o processo de desenvolvimento. Diferentemente de uma simples ferramenta de consulta, os modelos passaram a atuar como assistentes capazes de sugerir correções, identificar erros e fornecer feedback imediato durante a implementação das soluções. D3 exemplificou esse cenário ao relatar sua experiência com ferramentas integradas ao ambiente de desenvolvimento:

“Há um bom uso das LLMs para melhorar a qualidade de código dele. O Google Colab agora tem um assistente Gemini integrado e funciona ali quase como um parceiro de codificação. Ele já dá uma resposta de um problema que aparece no seu código. Às vezes a resposta é errada, mas também muitas vezes acerta. Então você tem um auxílio, o que já ajuda bastante. Essas ferramentas que estão ligadas ao raciocínio lógico do aluno ajudam muito, só não pode haver uma dependência muito grande. Como aconteceu com o Copilot, que foi absorvido pelo GitHub, uma ferramenta que corrige código.” (D3)

A percepção de D3 sugere que as LLMs podem atuar de maneira semelhante ao *pair programming*, oferecendo suporte contínuo durante a escrita e depuração do código. Esse resultado converge com estudos que apontam que ferramentas como ChatGPT, Gemini e GitHub Copilot podem auxiliar na identificação de erros, na geração de sugestões de implementação e na revisão de trechos de código [2]. Entretanto, a própria fala do docente evidencia que esses benefícios dependem da manutenção de uma postura crítica por parte do estudante, uma vez que as respostas produzidas pelos modelos nem sempre são corretas e precisam ser avaliadas antes de serem incorporadas à solução final.

Os benefícios também se manifestaram na qualidade dos projetos desenvolvidos em disciplinas avançadas. D8 observou que os estudantes passaram a alcançar resultados mais sofisticados e próximos de contextos profissionais reais:

“Eu percebo que o uso da LLM tem sido benéfico, porque eles conseguem ir mais longe nos projetos.” (D8)

“Eles já conseguem ir mais longe nos projetos, já são projetos mais realísticos, projetos mais profissionais.” (D8)

Esse resultado sugere que as LLMs não apenas aceleram o desenvolvimento, mas também ampliam o escopo das atividades desenvolvidas em disciplinas baseadas em projetos. Ao reduzir barreiras técnicas e oferecer suporte durante a implementação, os estudantes conseguem explorar soluções mais completas e enfrentar desafios que anteriormente demandariam níveis mais elevados de experiência. Como consequência, os projetos passam a se aproximar mais de cenários encontrados na prática profissional, favorecendo uma experiência de aprendizagem mais autêntica e alinhada às demandas do desenvolvimento de software contemporâneo.

Por fim, D3 destacou que, em conteúdos mais especializados, as próprias limitações das LLMs funcionam como um mecanismo que estimula a autonomia intelectual dos estudantes:

“Quando o conteúdo é mais nichado, menos informação é gerada. [...] Os LLMs não conseguem dar uma resposta suficiente para o problema que é apresentado. O aluno acaba tendo que explorar mais. Então, é muito bom para ele ter um ponto de partida [...]; depois, ele vai ter que se guiar.” (D3)

Curiosamente, nesse contexto, a limitação da ferramenta transforma-se em oportunidade de aprendizagem, uma vez que o estudante precisa complementar as respostas recebidas por meio de pesquisa, validação e exploração adicional do problema. Esse resultado reforça a ideia de que os benefícios das LLMs não decorrem apenas da qualidade das respostas produzidas, mas também da capacidade dos estudantes de utilizá-las como ponto de partida para a construção do conhecimento.

De modo geral, os resultados indicam que, quando utilizados por estudantes com maior maturidade acadêmica, os LLMs podem contribuir para a ampliação do repertório teórico, o desenvolvimento de software, a melhoria da qualidade do código, a execução de projetos mais sofisticados e o fortalecimento da autonomia intelectual. Esses achados reforçam a perspectiva de que os impactos educacionais das LLMs são fortemente condicionados pela capacidade dos estudantes de interpretar, validar e integrar criticamente as informações produzidas pelas ferramentas ao seu processo de aprendizagem.

Benefícios para a Prática Docente. Além dos impactos sobre os estudantes, os docentes relataram benefícios concretos para sua própria prática. Todos os participantes (100%) declararam utilizar LLMs em atividades acadêmicas, especialmente na preparação de aulas, elaboração de exercícios e avaliações, e produção de materiais didáticos. Esse dado é relevante porque demonstra que as mesmas ferramentas percebidas como risco para os estudantes são adotadas pelos docentes de forma reflexiva e orientada a objetivos pedagógicos claros.

D1 descreveu como usa as LLMs para enriquecer seus materiais de aula com exemplos mais claros e propor exercícios

mais variados. D9 destacou o impacto sobre a gestão do tempo:

“Vamos dizer que eu levasse três horas para construir um conjunto de slides para uma aula de uma hora e meia. Eu pego um material e vou orientando como é que eu gostaria desse conjunto. E, em cinco minutos, ele faz para mim. O que eu vou fazer com esse tempo que eu ganhei? Vou estudar mais a minha aula, vou preparar melhor a minha aula, porque a parte braçal, que é a construção do design, é uma coisa braçal mesmo, demanda tempo.” (D9)

D4 acrescentou que a redução do tempo de preparação permite explorar dinâmicas e estratégias que antes eram inviáveis:

“As ferramentas me permitem explorar algumas coisas, principalmente novas dinâmicas, novas ideias em aulas, que antes eu não fazia por questão de tempo [...]. Hoje eu consigo preparar uma dinâmica [...] que aí sim pode gerar um ganho cognitivo maior para os alunos.” (D4)

Os relatos indicam que, para os docentes, as LLMs contribuem para a realização de atividades relacionadas ao planejamento e à preparação das disciplinas. Ao automatizar tarefas operacionais, essas ferramentas permitem que os docentes dediquem mais tempo ao planejamento estratégico do ensino e ao acompanhamento da aprendizagem dos estudantes. Em contrapartida, os relatos também apontam que parte dos estudantes tende a utilizar as LLMs de forma menos reflexiva, delegando etapas importantes do processo de resolução de problemas. Esse contraste sugere que os benefícios educacionais dessas tecnologias dependem não apenas de suas funcionalidades, mas também da forma como seu uso é orientado e integrado às práticas pedagógicas.

Em síntese, os resultados permitem responder à RQ2 indicando que os docentes identificam tanto benefícios quanto preocupações associados ao uso das LLMs em disciplinas de programação. Entre os principais benefícios destacam-se a ampliação do repertório dos estudantes, o apoio à resolução de problemas em contextos avançados, a melhoria da qualidade dos projetos e os ganhos obtidos pelos próprios docentes na preparação de materiais e estratégias pedagógicas. As principais preocupações concentram-se na dependência excessiva da ferramenta, na redução da autonomia cognitiva, no enfraquecimento do raciocínio lógico e no risco de dissociação entre a qualidade aparente das entregas e a compreensão efetiva dos conteúdos. O conjunto dos relatos indica que a maturidade acadêmica opera como variável moderadora central: os benefícios tendem a ser mais evidentes em disciplinas avançadas e em estudantes com base conceitual consolidada, enquanto as preocupações se concentram nos contextos introdutórios, nos quais a mediação docente assume papel determinante para promover um uso crítico, reflexivo e pedagogicamente orientado dessas tecnologias.




Figure 4: Frequência de ativação dos códigos associados à RQ2.

9.3 Como os docentes de programação têm adaptado suas práticas de avaliação após a popularização da IA generativa? (RQ3)

Os resultados indicam que os docentes não permaneceram apenas observando os impactos das LLMs sobre a aprendizagem, mas passaram a adaptar suas práticas avaliativas para lidar com a nova realidade educacional. A mudança mais frequentemente relatada foi a redução da confiança em atividades realizadas fora do ambiente supervisionado, levando à adoção de mecanismos capazes de verificar não apenas o produto entregue, mas também o processo de construção do conhecimento. Esse resultado converge com as reflexões de Raabe et al. [23], que destacam a importância de acompanhar o desenvolvimento da aprendizagem em disciplinas de programação, e não apenas os resultados finais produzidos pelos estudantes.

Uma das estratégias mais recorrentes foi a realização de arguições e discussões presenciais, nas quais os estudantes precisam explicar o raciocínio utilizado para construir suas soluções. D3 descreveu essa prática da seguinte forma:

“O que eu faço é dividir os trabalhos em equipes. E aí, eu passo os trabalhos e faço uma espécie de arguição em sala de aula, pra pegar como foi que eles construíram aquele código, aquela ideia, o que veio por trás. Porque mesmo que o cara construa aquilo por IA, ele vai se preocupar em ver como é que ele vai responder.” (D3)

Além das arguições, alguns docentes relataram a redistribuição dos pesos das avaliações, reduzindo a relevância de listas de exercícios e trabalhos extraclasse e ampliando a participação de provas presenciais na composição da nota final. Segundo os participantes, essa mudança busca minimizar dificuldades relacionadas à identificação da autoria das atividades e garantir que a avaliação reflita efetivamente os conhecimentos construídos pelos estudantes. Estratégias semelhantes também foram observadas por Lau e Guo [13],

que identificaram uma valorização crescente de avaliações supervisionadas em cursos de Computação.

Outro resultado relevante foi a adoção de modelos avaliativos que incorporam explicitamente o uso das LLMs. Em vez de avaliar apenas as respostas produzidas pelas ferramentas, alguns docentes passaram a valorizar a capacidade dos estudantes de formular instruções adequadas e analisar criticamente os resultados obtidos. Essa inversão avaliativa foi descrita por D9 com particular precisão:

“Não vou avaliar a resposta que o prompt vai te dar, vou avaliar o prompt que você fez. Aí você inverte, porque hoje em dia a gente não está mais naquela vibe de em busca das respostas corretas. Claro, a gente está buscando as respostas corretas, mas a gente tá buscando as melhores perguntas. E essas ferramentas, elas só vão te dar uma boa resposta se você fizer boas perguntas. [...] Saiba perguntar. E não pense que saber fazer uma boa pergunta com objetividade, com clareza, com concisão, é trivial. Não é. A habilidade de comunicação com a ferramenta é fundamental.” (D9)

Essa abordagem encontra respaldo em White et al. [33], que argumentam que a elaboração de *prompts* eficazes demanda conhecimento do conteúdo, capacidade de comunicação e organização do pensamento. Dessa forma, a avaliação passa a considerar não apenas o resultado final, mas também o processo cognitivo empregado pelo estudante na interação com a ferramenta.

Um conjunto de docentes avançou para além da postura defensiva de tentar evitar o uso das LLMs e passou a incorporá-las explicitamente como objeto e instrumento das atividades pedagógicas. Essa abordagem parte do reconhecimento de que a proibição é ineficaz e de que a integração orientada representa uma resposta mais consistente com as demandas da formação contemporânea em programação. D8, por exemplo, relatou o uso de uma LLM como cliente virtual em atividades de levantamento de requisitos:

“O Gemini assumia o papel de um cliente. E aí cada equipe tinha um segmento de cliente, então era como se cada equipe visitasse os setores da empresa e entrevistasse, conversasse via chat com um possível cliente, mesmo que fosse virtual. Então isso é uma aula prática que tem o uso da IA, não tem problema. Eu ainda acho que foi melhor do que não ter nenhum cliente.” (D8)

D6 descreveu uma estratégia em que o uso da LLM é não apenas permitido, mas solicitado, com a diferença de que o foco da avaliação recai sobre a análise crítica do resultado gerado pela ferramenta, e não sobre o resultado em si:

“Eu falo assim, utiliza a IA para fazer isso. Mas, depois que ela trouxe o resultado, valide com tudo que você aprendeu e faça uma análise crítica em cima daquilo que a IA gerou pra você. Isso é mais recente, eu acabei abordando isso no último semestre, e pelo menos a priori os alunos

gostaram dessa prática que eles exercitaram. Então acho que eu pretendo explorar isso um pouco mais.” (D6)

D7 propôs uma abordagem ainda mais provocativa, que consiste em instruir a LLM a fornecer respostas deliberadamente incorretas, transformando a detecção do erro em objeto de aprendizagem e exercício de raciocínio crítico:

“Eu posso até usar uma IA e dizer pra ela, olha, vou fazer um exercício aqui em sala e eu quero que você dê respostas erradas para aquilo que eu vou perguntar. E aí eu vou perguntar aqui um negócio sobre programação. E os alunos vão ter que identificar o erro. Então assim, posso usar esse tipo de brincadeira para estimular que eles pensem. A grande questão é estimular que eles realmente possam produzir um efeito por eles mesmos.” (D7)

Essas práticas aproximam-se dos resultados observados por Sarsa et al. [27], que destacam o potencial das ferramentas de IA para estimular reflexão, análise crítica e aprendizagem ativa quando utilizadas de forma orientada.

De maneira geral, os resultados sugerem que a adaptação dos docentes tem ocorrido em duas frentes complementares: o fortalecimento de mecanismos que permitam verificar a autoria e a compreensão dos estudantes e a incorporação gradual das LLMs como recursos pedagógicos capazes de apoiar processos de ensino e aprendizagem. Em ambos os casos, observa-se uma redefinição das práticas avaliativas, com maior ênfase na demonstração do raciocínio, na argumentação e na capacidade de analisar criticamente os resultados produzidos por sistemas de IA.

A Figura 5 sintetiza o modelo conceitual emergente da análise qualitativa realizada para a RQ3. O modelo evidencia que as adaptações docentes não se restringem à adoção de mecanismos de controle para mitigar o uso inadequado das LLMs, mas também incluem estratégias voltadas à sua integração pedagógica. Essas duas frentes convergem para um novo enfoque avaliativo, centrado menos no produto final e mais na demonstração do processo de construção do conhecimento, no raciocínio desenvolvido pelo estudante e em sua capacidade de utilizar criticamente ferramentas de IA.

A Figura 3 apresenta a frequência de ativação dos códigos associados à RQ3, organizados nas categorias CAT. 3 (Estratégias de adaptação docente), CAT. 6 (Adaptações metodológicas e avaliativas).

9.4 Quais desafios éticos os docentes percebem no uso de IA generativa no ensino de programação? (RQ4)

Os resultados indicam que os desafios éticos associados ao uso de LLMs no ensino de programação se manifestam em três níveis complementares: o comportamento dos estudantes durante a realização das atividades acadêmicas, a responsabilidade do docente na mediação do uso dessas ferramentas



Figure 5: Modelo conceitual das adaptações das práticas avaliativas docentes identificadas na RQ3.

e a ausência de diretrizes institucionais claras para orientar essas práticas.

No primeiro nível, os docentes relataram situações em que conteúdos produzidos por ferramentas de IA eram apresentados como trabalho autoral dos estudantes, sem transparência sobre o uso da ferramenta ou reflexão crítica sobre os resultados gerados. Essas práticas aproximam-se das categorias de desonestidade acadêmica descritas por Jones [7], especialmente aquelas relacionadas à autoria indevida e à apresentação de produções de terceiros como próprias.

Os participantes também destacaram que o debate sobre autoria intelectual se tornou mais complexo com a popularização das LLMs. Em vez de avaliar apenas o produto final entregue, os docentes passaram a valorizar a capacidade do estudante de explicar, justificar e defender as soluções produzidas. Nessa perspectiva, a autoria deixa de estar associada exclusivamente à escrita do código ou do texto e passa a envolver o processo de interação, revisão e validação das respostas geradas pela IA. D9 sintetizou esse entendimento:




Figure 6: Frequência de ativação dos códigos associados à RQ3.

“Se o aluno usou um LLM para resolver um exercício de programação, seja verdadeiro. Diga, eu usei. Se ele pelo menos consultou a IA, escreveu um prompt, e percebeu que tinha uns problemas e corrigiu, aí você pensou. Então, o princípio ético é o aluno ser verdadeiro. Ele não mentir. Ele ser verdadeiro com ele mesmo.” (D9)

Esse resultado dialoga com discussões recentes da literatura sobre autoria e integridade acadêmica em contextos mediados por IA. Enquanto alguns estudos associam o uso indiscriminado dessas ferramentas a práticas de plágio e desonestidade acadêmica [17], outros argumentam que a interação com sistemas generativos envolve processos de elaboração, revisão e adaptação que não podem ser reduzidos a uma simples reprodução de conteúdo [20]. Os relatos dos docentes sugerem uma posição intermediária, na qual o uso da ferramenta não é necessariamente considerado inadequado, desde que exista transparência e participação efetiva do estudante na construção da solução.

Os casos relatados pelos docentes mostram que o uso indevido das LLMs deixa marcas reconhecíveis nas entregas dos estudantes. D10 e D6 descreveram como identificam essas situações pela própria forma do material recebido. D10 relatou que consegue perceber a mudança no meio do texto:

“Quando a gente está analisando a escrita, quando a gente vai ler um trabalho, com muita facilidade a gente consegue discernir. Até essa página, foi uma pessoa que escreveu, a partir dessa página é outro estilo de escrita.” (D10)

D6 foi além e descreveu situações em que o próprio formato da entrega denunciava o uso da ferramenta, inclusive com marcas deixadas pelo ChatGPT no texto:

“Veio formatado como se fosse uma IA que gerou. Vem um formato característico, com alguns ícones. E às vezes até uma frase do próprio ChatGPT no final: você deseja que te ajude com mais alguma

coisa? Então, nesse cenário, eu penalizava com nota.” (D6)

Ao se depararem com essas situações, os docentes reagiram de formas bastante diferentes. Alguns optaram por mudar a forma de avaliar, reduzindo ou eliminando atividades que os alunos pudessem fazer em casa sem supervisão. D1 contou que chegou a inverter quase completamente a distribuição de pontos da disciplina:

“Antes da LLM, eu detectava muito plágio. Depois da LLM ficou um pouco mais difícil. Então eu alterei minha abordagem na disciplina. Hoje eu distribuo acho que 90 pontos em prova e só 10 pontos de exercício. Quem não faz o trabalho acaba que paga por isso na prova. Porque aí chega na hora da prova, a prova tá aqui, ou você sabe ou você não sabe.” (D1)

D5 viveu uma situação ainda mais emblemática, em que o volume de trabalhos idênticos tornou a atividade inviável como forma de avaliação:

“Quando começou a IA, passei um trabalho. Tinha uns cinco semestres. 80% iguais, eles começaram a rir. É igual, igual, igual. Eu disse, vocês querem que eu corrija? Porque se eu corrijo dois trabalhos iguais, vou zerar. Eles optaram por cancelar.” (D5)

D9, por sua vez, escolheu um caminho diferente. Em vez de punir ou restringir, ele chamou o aluno para conversar e pediu para ver como a ferramenta havia sido usada. Para ele, o que importa não é só a resposta entregue, mas entender como o aluno chegou até ela:

“Chamei o aluno para conversar. Aí eu falo, sim professor, usei. Tá, beleza. Agora me explica aqui como foi. Deixa eu dar uma olhada no prompt que você escreveu. Ih, professor, eu joguei fora. Cara, eu queria ver o teu raciocínio. Porque aí eu mostro pra ele que o meu interesse não é só na resposta que ele me deu. Eu quero entender o raciocínio dele.” (D9)

Apesar das diferenças de abordagem, os três relatos apontam para um mesmo movimento: o foco da avaliação está deixando de ser o produto final entregue e passando a ser o processo pelo qual o estudante chegou àquela solução.

Um segundo desafio ético identificado pelos docentes diz respeito à responsabilidade do próprio professor na mediação do uso das LLMs. Vários participantes expressaram a percepção de que abandonar o estudante sem orientação diante dessas ferramentas é uma postura eticamente problemática, pois compromete diretamente a qualidade da formação. D9 foi direto ao afirmar que o preparo do docente é condição necessária para um uso responsável:

“Essas ferramentas, se não forem bem conduzidas, os estudantes precisam que os professores estejam preparados para orientar eles no uso dessas ferramentas. Se a gente eslargar esses meninos

sozinhos, nós estamos comprometendo o futuro deles.” (D9)

Esse desafio se estende para além do ambiente acadêmico. D8 relatou o caso de um estudante de fisioterapia que estava desenvolvendo um sistema para clínicas usando apenas a IA, sem entender o que estava sendo construído, e pretendendo comercializá-lo como produto próprio:

“Ele disse que tava desenvolvendo um sistema para clínicas de fisioterapia. Eu disse, tu tá entendendo o que ela tá fazendo? Ele, nada, mas eu vou dizendo o que tá acontecendo e ela vai mandando eu corrigir e tá dando certo. Cara, tu vai se responsabilizar pelo que vai acontecer? Você é fisioterapeuta, então trabalha com fisioterapia. E deixa o sistema pra quem tá estudando sistemas.” (D8)

Esse relato evidencia que o desafio ético do uso irresponsável das LLMs não se limita ao contexto acadêmico, mas se projeta para a vida profissional dos egressos, onde as consequências de assumir a autoria de soluções que não se compreende podem ser muito mais graves.

No âmbito institucional, os participantes demonstraram consenso quanto à insuficiência de políticas e orientações formais para o uso de IA generativa no contexto acadêmico. Os docentes relataram incertezas sobre limites aceitáveis de utilização, critérios de avaliação e formas adequadas de integrar essas tecnologias às atividades de ensino. D7 resumiu essa percepção:

“Não está clara em lugar nenhum. Nem na academia, nem na empresa. É tudo muito novo. As pessoas não sabem muito bem pra onde vão. O que eu tenho sugerido para todo mundo é criar os comitês de IA. Não é para proibir, é para entender como é que vai usar.” (D7)

A ausência de diretrizes institucionais foi percebida como um fator que dificulta tanto a atuação docente quanto a compreensão dos estudantes sobre práticas aceitáveis de uso. Os resultados sugerem que, diante da rápida disseminação das LLMs, os desafios éticos não estão relacionados apenas ao comportamento individual dos estudantes, mas também à responsabilidade dos docentes em orientar esse uso e à necessidade de construção de políticas institucionais capazes de dar suporte a esse processo.

A Figura 7 apresenta a frequência de ativação dos códigos associados à RQ4, obtida por meio da análise de conteúdo segundo Bardin. Observa-se que o código *Ausência de diretrizes institucionais* apresentou a maior frequência de ativação (100%), evidenciando que a inexistência de políticas formais para o uso das LLMs constitui a principal preocupação dos docentes participantes. Em seguida, destacam-se os códigos *Transparência e autoria* (80%), *Indícios de uso de IA* (70%) e *Estruturas não ensinadas* (60%), indicando que os docentes frequentemente recorrem a evidências presentes nas produções dos estudantes para identificar o uso das ferramentas. Os códigos relacionados à *Conversa individual com*




Figure 7: Frequência de ativação dos códigos associados à RQ4.

o estudante (50%), Falta de padronização (50%), Direito intelectual (40%), Políticas institucionais em construção (40%) e Referências bibliográficas (30%) apresentaram menor frequência de ativação, sugerindo que essas questões também fazem parte das discussões docentes, embora com menor recorrência. De modo geral, os resultados indicam que as principais preocupações dos participantes concentram-se na necessidade de estabelecer diretrizes institucionais claras, fortalecer mecanismos de transparência e autoria e desenvolver estratégias mais consistentes para lidar com o uso das LLMs em atividades avaliativas.

10 CONCLUSÃO

Este estudo investigou as percepções de docentes de programação sobre o uso de LLMs no contexto educacional. Os resultados indicam que essas ferramentas já estão amplamente incorporadas ao cotidiano dos estudantes e têm provocado mudanças nas práticas de ensino e avaliação. Os docentes reconhecem que as LLMs podem apoiar a aprendizagem, ampliar o repertório dos alunos e atuar como suporte complementar ao desenvolvimento de atividades de programação. Além disso, foi observado que os próprios professores utilizam essas ferramentas para auxiliar no planejamento de aulas, na elaboração de materiais didáticos e no desenvolvimento de estratégias pedagógicas.

Entre os principais achados, destaca-se a percepção de que os benefícios das LLMs tendem a ser mais evidentes entre estudantes que já apresentam maior autonomia e domínio dos fundamentos da programação, enquanto alunos com dificuldades prévias podem desenvolver dependência excessiva da ferramenta. Como diferencial, a pesquisa contemplou docentes que atuam tanto em disciplinas introdutórias quanto em disciplinas avançadas de programação, permitindo identificar que os impactos das LLMs variam de acordo com o estágio de formação dos estudantes.

Os resultados também revelaram divergências entre os docentes quanto ao uso dessas ferramentas nas disciplinas

iniciais. Enquanto alguns defendem a adoção de restrições em determinados contextos para evitar prejuízos ao desenvolvimento dos fundamentos da programação, outros argumentam que a proibição não é uma estratégia efetiva, defendendo a integração das LLMs por meio de metodologias que promovam seu uso crítico, consciente e alinhado aos objetivos de aprendizagem. Em conjunto, os achados evidenciam a necessidade de repensar práticas pedagógicas e avaliativas diante da crescente presença da IA generativa nas disciplinas de programação.

REFERENCES

- [1] Laurence Bardin. 2016. *Análise de Conteúdo* (1 ed.). Edições 70, São Paulo.
- [2] Centro de Inovação e Desenvolvimento em Engenharia. 2026. *Geração de código por modelos de linguagem (LLMs): potencialidades, riscos e responsabilidades éticas*. <https://ww2.ufjf.br/cideng/2026/05/15/geracao-de-codigo-por-modelos-de-linguagem-llms-potencialidades-riscos-e-responsabilidades-eticas/>
- [3] M. V. Cranach, E. Mächler, and V. Steiner. 1985. *The organization of goal-directed action: a research report*. Academic Press, London, 19–61.
- [4] Jorge Duarte. 2005. *Entrevista em profundidade*. Atlas, São Paulo.
- [5] IBM. 2024. *O que são alucinações em IA?* IBM. <https://www.ibm.com/br-pt/think/topics/ai-hallucinations>
- [6] IBM. 2025. *What Are Large Language Models (LLMs)?* <https://www.ibm.com/think/topics/large-language-models>. Acesso em: 1 fev. 2026.
- [7] Karl O. Jones, Reid Juliet, and Bartlett Rebecca. 2008. Cyber Cheating in an Information Technology Age. *Digithum* 10 (Dec. 2008). <https://raco.cat/index.php/Digithum/article/view/394993> Acesso em: 26 maio 2026.
- [8] Gregor Jošt, Viktor Taneski, and Sašo Karakatič. 2024. The Impact of Large Language Models on Programming Education and Student Learning Outcomes. *Applied Sciences* 14, 10 (2024), 4115. doi:10.3390/app14104115
- [9] Daniel Jurafsky and James H. Martin. 2023. *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition* (3 ed.). Prentice-Hall, Upper Saddle River, NJ, USA. https://web.stanford.edu/~jurafsky/slp3/ed3book_jan72023.pdf Accessed: 30 Apr. 2025.
- [10] Vassilka Kirova, Cyril Ku, Joseph Laracy, and Thomas Marlowe. 2024. Software Engineering Education Must Adapt and Evolve for an LLM Environment. In *Proceedings of the 55th ACM Technical Symposium on Computer Science Education V. 1 (SIGCSE 2024)*. Association for Computing Machinery, 666–672. doi:10.1145/3626252.3630927
- [11] Nataliya Kosmyna, Eugene Hauptmann, Ye Tong Yuan, Jessica Situ, Xian-Hao Liao, Ashly Vivian Beresnitzky, Iris Braunstein, and Pattie Maes. 2025. Your Brain on ChatGPT: Accumulation of Cognitive Debt when Using an AI Assistant for Essay Writing Task. *arXiv preprint arXiv:2506.08872* (2025). <https://arxiv.org/abs/2506.08872> Acesso em: 26 maio 2026.
- [12] Muralidhar Kurni, Mujeeb Mohammed, and K. Srinivasa. 2023. *Chatbots for Education*. Springer, 173–198. doi:10.1007/978-3-031-32653-0_10
- [13] Sam Lau and Philip J. Guo. 2023. From "Ban It Till We Understand It" to "Resistance is Futile": How University Programming Instructors Plan to Adapt as More Students Use AI Code Generation and Explanation Tools such as ChatGPT and GitHub Copilot. In *Proceedings of the 2023 ACM Conference on International Computing Education Research - Volume 1*. ACM, New York, NY, USA, 1–16. doi:10.1145/3568813.3600138
- [14] Shaila Maia and Laura Sarkis. 2025. Utilização de LLM como Ferramenta de Apoio no Ensino-Aprendizagem de Programação Python para Iniciantes: Um Relato de Experiência. In *Anais do XXXIII Workshop sobre Educação em Computação (Maceió/AL)*. SBC, Porto Alegre, RS, Brasil, 385–396. doi:10.5753/we.2025.8107

- [15] E. J. Manzini. 2003. *Considerações sobre a elaboração de roteiro para entrevista semi-estruturada*. Eduel, Londrina, 11–25.
- [16] OpenAI. 2023. Como o ChatGPT está transformando a programação. <https://openai.com/blog/chatgpt-transformando-a-programacao/>. Acesso em: 23 maio 2026.
- [17] Michael Sheinman Orenstrakh, Oscar Karnalim, Carlos Anibal Suarez, and Michael Liut. 2023. Detecção de texto gerado por LLM na educação em computação: um estudo comparativo para casos do ChatGPT. *arXiv preprint arXiv:2307.07411* (2023). arXiv:2307.07411 [cs.CL] <https://arxiv.org/abs/2307.07411>
- [18] Luiz C. Pereira Filho, Talita de P. C. de Souza, and Luciano Bernardes de Paula. 2023. Análise das Respostas do ChatGPT em Relação ao Conteúdo de Programação para Iniciantes. In *Anais do Simpósio Brasileiro de Informática na Educação (SBIE)*. Sociedade Brasileira de Computação, Passo Fundo, RS, 1738–1748. doi:10.5753/sbie.2023.234870
- [19] Alain Pinsonneault and Kenneth L. Kraemer. 1993. Survey Research Methodology in Management Information Systems: An Assessment. *Journal of Management Information Systems* 10, 2 (1993), 75–105. doi:10.1080/07421222.1993.11518001
- [20] James Prather, Paul Denny, Juho Leinonen, Brett A. Becker, Ibrahim Albluwi, Michelle Craig, Hieke Keuning, Natalie Kiesler, Tobias Kohn, and Andrew Luxton-Reilly. 2023. The Robots Are Here: Navigating the Generative AI Revolution in Computing Education. 108–159 pages. doi:10.1145/3623762.3633499
- [21] James Prather, Brent N. Reeves, Paul Denny, Brett A. Becker, Juho Leinonen, Andrew Luxton-Reilly, Garrett Powell, James Finnie-Ansley, and Eddie Antonio Santos. 2023. “It’s Weird That It Knows What I Want”: Usability and Interactions with Copilot for Novice Programmers. *ACM Transactions on Computer-Human Interaction* 31, 1 (2023), 1–31. doi:10.1145/3617367
- [22] Junaid Qadir. 2022. Engineering Education in the Era of ChatGPT: Promise and Pitfalls of Generative AI for Education. (2022). doi:10.36227/techrxiv.21789434
- [23] André Luís Alice Raabe and JMC da Silva. 2005. Um ambiente para atendimento às dificuldades de aprendizagem de algoritmos. In *XIII Workshop de Educação em Computação (WEI)*. São Leopoldo, RS, Brasil.
- [24] Md. Mostafizer Rahman and Yutaka Watanobe. 2023. ChatGPT for Education and Research: Opportunities, Threats, and Strategies. *Applied Sciences* 13, 9 (2023), 5783. doi:10.3390/app13095783
- [25] Savio Sampaio, Marcia Lima, Eriky Rodrigues, Maria Meireles, Marcela Sávia Picanço Pessoa, and Tayana Conte. 2024. Exploring the Use of Large Language Models in Requirements Engineering Education: An Experience Report with ChatGPT 3.5. In *Proceedings of the XXXVIII Brazilian Symposium on Software Engineering (SBES 2024)*. doi:10.1145/3701625.3701687
- [26] Pamela Samuelson. 2020. AI Authorship? *Commun. ACM* 63, 7 (June 2020), 20–22. doi:10.1145/3401718
- [27] Sami Sarsa, Paul Denny, Arto Hellas, and Juho Leinonen. 2022. Automatic Generation of Programming Exercises and Code Explanations Using Large Language Models. In *Proceedings of the 2022 ACM Conference on International Computing Education Research (ICER 2022)*. Association for Computing Machinery, New York, NY, USA, 27–43. doi:10.1145/3501385.3543957
- [28] Francisco Silva and Eduardo Aranha. 2025. LLMs na Educação em Programação: Estratégias para Avaliação e Feedback Formativo. In *Anais Estendidos do V Simpósio Brasileiro de Educação em Computação* (Juiz de Fora, MG). SBC, Porto Alegre, RS, Brasil, 81–87. doi:10.5753/educomp_estendido.2025.6614
- [29] Teresinha Silva, Kajiana Vidotto, Liane Tarouco, and Patricia Silva. 2024. Inteligência artificial generativa no ensino de programação: um mapeamento sistemático da literatura. *RENOTE* 22 (07 2024), 262–272. doi:10.22456/1679-1916.141553
- [30] A. H. Souleiman. 2017. Orchestration and Adaptation of Learning Scenarios: Application to the Case of Programming Learning/Teaching. In *2017 IEEE/ACS 14th International Conference on Computer Systems and Applications (AICCSA)*. IEEE, 7–11.
- [31] Yi-Hsuan Tang, Yu-Hao Wang, Eibe Frank, Yi Sun, Jun Yu, Subhabrata Dey, Yizhou Feng, Jie Yang, Srikanth Sathe, Ming Zhou, and Peng Chen. [n.d.]. ChatGPT for Good: On Opportunities and Challenges of Large Language Models for Education. *arXiv* [n.d.].
- [32] Tianjia Wang, Daniel Vargas-Diaz, Chris Brown, and Yan Chen. 2023. Exploring the Role of AI Assistants in Computer Science Education: Methods, Implications, and Instructor Perspectives. *arXiv preprint arXiv:2306.03289* (2023). doi:10.48550/arXiv.2306.03289
- [33] Jules White, Quchen Fu, Sam Hays, Michael Sandborn, Carlos Olea, Henry Gilbert, Ashraf Elnashar, Jesse Spencer-Smith, and Douglas C. Schmidt. 2023. A Prompt Pattern Catalog to Enhance Prompt Engineering with ChatGPT. *arXiv* (2023). arXiv:2302.11382 [cs.SE] <https://arxiv.org/abs/2302.11382>
- [34] Yuankai Xue, Hanlin Chen, Gina R. Bai, Robert Tairas, and Yu Huang. 2024. Does ChatGPT Help With Introductory Programming? An Experiment of Students Using ChatGPT in CS1. In *Proceedings of the 46th International Conference on Software Engineering: Software Engineering Education and Training (ICSE-SEET)*. ACM, 331–341. doi:10.1145/3639474.3640076
- [35] Igor Yepes and Andre Fiorin. 2023. ChatGPT como Assistente de Ensino na Disciplina de Estruturas de Dados. In *Anais do XIV Encontro de Alunos de Tecnologia da Informacao*. Frederico Westphalen, RS.
- [36] Cynthia Zastudil, Magdalena Rogalska, Christine Kapp, Jennifer Vaughn, and Stephen MacNeil. 2023. Generative Artificial Intelligence in Computing Education: Perspectives of Students and Instructors. In *2023 IEEE Frontiers in Education Conference (FIE)*. 1–9. doi:10.1109/FIE58773.2023.10343467